

CPE 342 Machine Learning

Assignment 1: Training Models

OLS Regression

67070501042 วิศิษฐ์ สุวรรณเนา

ข้อมูลที่กำหนดให้เป็นตัวเลขงบประมาณโฆษณา (X , หน่วย: พันดอลลาร์) และยอดขาย (Y , หน่วย: พันหน่วย) จาก 10 เดือน ดังนี้

Month	Advertising Budget X (\$1,000s)	Sales Y (1,000 units)
1	3.0	6.0
2	5.0	9.0
3	2.0	4.0
4	7.0	10.0
5	8.0	12.0
6	1.0	3.0
7	4.0	7.0
8	6.0	8.0
9	9.0	13.0
10	10.0	15.0

Task 1: Implement OLS Regression

1a) Fit Simple Linear Regression ด้วยวิธี OLS

แบบจำลอง: สมมติว่าความสัมพันธ์ระหว่าง X กับ Y เป็นเชิงเส้น (linear) กำหนดให้ $\hat{Y}_i = \alpha + \beta X_i$ โดยที่ α คือ intercept และ β คือ slope

แทน $Y_i = \beta X_i + \alpha$ ลงในสมการ error $\varepsilon_i = Y_i - \hat{Y}_i$ จะได้

$$\varepsilon_i = Y_i - (\alpha + \beta X_i)$$

หลักการของ OLS: พยายามลดผลรวมของกำลังสองของ error (Least Squares Function) S :

$$S(\alpha, \beta) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (Y_i - \alpha - \beta X_i)^2$$

ฟังก์ชัน S จะมีค่าน้อยที่สุดเมื่อ $\frac{\partial S}{\partial \alpha} = 0$ และ $\frac{\partial S}{\partial \beta} = 0$

การหา partial derivatives:

$$\frac{\partial S}{\partial \alpha} = -2 \sum_{i=1}^n (Y_i - \alpha - \beta X_i) = 0 \quad (1)$$

$$\frac{\partial S}{\partial \beta} = -2 \sum_{i=1}^n (Y_i - \alpha - \beta X_i) X_i = 0 \quad (2)$$

จากสมการ (1): $\sum_{i=1}^n Y_i - n\alpha - \beta \sum_{i=1}^n X_i = 0 \implies$ **Normal Equation 1:**

$$n\alpha + \beta \sum_{i=1}^n X_i = \sum_{i=1}^n Y_i$$

จากสมการ (2): $\sum_{i=1}^n X_i Y_i - \alpha \sum_{i=1}^n X_i - \beta \sum_{i=1}^n X_i^2 = 0 \implies$ **Normal Equation 2:**

$$\alpha \sum_{i=1}^n X_i + \beta \sum_{i=1}^n X_i^2 = \sum_{i=1}^n X_i Y_i$$

สามารถเขียน Normal Equation ในรูปแบบ Matrix ได้ดังนี้:

$$\begin{bmatrix} n & \sum X_i \\ \sum X_i & \sum X_i^2 \end{bmatrix} \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = \begin{bmatrix} \sum Y_i \\ \sum X_i Y_i \end{bmatrix}$$

คำนวณค่า summation จากข้อมูล:

i	X_i	Y_i	$X_i Y_i$	X_i^2
1	3.0	6.0	18.0	9.0
2	5.0	9.0	45.0	25.0
3	2.0	4.0	8.0	4.0
4	7.0	10.0	70.0	49.0
5	8.0	12.0	96.0	64.0
6	1.0	3.0	3.0	1.0
7	4.0	7.0	28.0	16.0
8	6.0	8.0	48.0	36.0
9	9.0	13.0	117.0	81.0
10	10.0	15.0	150.0	100.0
$\sum$	55.0	87.0	583.0	385.0

ดังนั้น:

$$n = 10, \quad \sum X_i = 55, \quad \sum Y_i = 87, \quad \sum X_i Y_i = 583, \quad \sum X_i^2 = 385$$

สรุป 1a: จากข้อมูลข้างต้น จะได้ระบบสมการ:

$$\begin{bmatrix} 10 & 55 \\ 55 & 385 \end{bmatrix} \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = \begin{bmatrix} 87 \\ 583 \end{bmatrix}$$

1b) คำนวณ Regression Coefficients

เราสามารถหาค่า α (intercept) และ β (slope) ได้หลายวิธี:

วิธีที่ 0: สูตร S_{xx}, S_{xy} (Closed-form จาก Normal Equations)

จาก Normal Equations สามารถแก้หาค่า β ได้โดยตรงด้วยการนิยามทั้งสองแบบ:

$$S_{xx} = \sum_{i=1}^n (X_i - \bar{X})^2 = \sum X_i^2 - \frac{(\sum X_i)^2}{n} = 385 - \frac{55^2}{10} = 385 - 302.5 = 82.5$$

$$S_{xy} = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) = \sum X_i Y_i - \frac{\sum X_i \sum Y_i}{n} = 583 - \frac{(55)(87)}{10} = 583 - 478.5 = 104.5$$

จะได้:

$$\beta = \frac{S_{xy}}{S_{xx}} = \frac{104.5}{82.5} \approx 1.2667, \quad \alpha = \bar{Y} - \beta \bar{X} = 8.7 - (1.2667)(5.5) \approx 1.7333$$

วิธีนี้ให้ผลลัพธ์ที่ตรงกันกับทุกวิธีอื่น แต่คำนวณได้เร็วกว่าเพราะไม่ต้องแก้ระบบสมการ

Listing 1: OLS computation using S_{xx}/S_{xy} method

สามารถเขียนด้วยโค้ด Python:

```

1 import numpy as np
2
3 X = np.array([3.,5.,2.,7.,8.,1.,4.,6.,9.,10.])
4 Y = np.array([6.,9.,4.,10.,12.,3.,7.,8.,13.,15.])
5
6 X_bar, Y_bar = X.mean(), Y.mean()      # 5.5, 8.7
7 Sxx = np.sum((X - X_bar)**2)           # 82.5
8 Sxy = np.sum((X - X_bar)*(Y - Y_bar))  # 104.5
9
10 beta = Sxy / Sxx                       # 1.266667
11 alpha = Y_bar - beta * X_bar           # 1.733333
12
13 print(f"beta = {beta:.6f}")
14 print(f"alpha = {alpha:.6f}")
15 print(f"Fitted: Y_hat = {alpha:.4f} + {beta:.4f}*X")

```

```

beta = 1.266667
alpha = 1.733333
Fitted: Y_hat = 1.7333 + 1.2667*X

```

วิธีที่ 1: Cramer's Rule

จากระบบสมการ:

$$10\alpha + 55\beta = 87$$

$$55\alpha + 385\beta = 583$$

หาค่า Determinant:

$$\Delta = \det \begin{bmatrix} 10 & 55 \\ 55 & 385 \end{bmatrix} = (10)(385) - (55)(55) = 3850 - 3025 = 825$$

$$\Delta_\alpha = \det \begin{bmatrix} 87 & 55 \\ 583 & 385 \end{bmatrix} = (87)(385) - (55)(583) = 33495 - 32065 = 1430$$

$$\Delta_\beta = \det \begin{bmatrix} 10 & 87 \\ 55 & 583 \end{bmatrix} = (10)(583) - (87)(55) = 5830 - 4785 = 1045$$

จะได้:

$$\alpha = \frac{\Delta_\alpha}{\Delta} = \frac{1430}{825} = \frac{26}{15} \approx 1.7333$$

$$\beta = \frac{\Delta_\beta}{\Delta} = \frac{1045}{825} = \frac{19}{15} \approx 1.2667$$

วิธีที่ 2: Pseudoinverse Method

กำหนด $A = \begin{bmatrix} 1 & X_1 \\ 1 & X_2 \\ \vdots & \vdots \\ 1 & X_n \end{bmatrix}$, $Y = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}$, และ $c = \begin{bmatrix} \alpha \\ \beta \end{bmatrix}$

จากสมการ $Ac = Y$ เราใช้ Left Pseudoinverse:

$$c = (A^T A)^{-1} A^T Y$$

จากตารางคำนวณ:

$$A^T A = \begin{bmatrix} n & \sum X_i \\ \sum X_i & \sum X_i^2 \end{bmatrix} = \begin{bmatrix} 10 & 55 \\ 55 & 385 \end{bmatrix}$$

$$A^T Y = \begin{bmatrix} \sum Y_i \\ \sum X_i Y_i \end{bmatrix} = \begin{bmatrix} 87 \\ 583 \end{bmatrix}$$

หา $(A^T A)^{-1}$:

$$(A^T A)^{-1} = \frac{1}{825} \begin{bmatrix} 385 & -55 \\ -55 & 10 \end{bmatrix}$$

คำนวณหา c :

$$\begin{aligned} c &= \frac{1}{825} \begin{bmatrix} 385 & -55 \\ -55 & 10 \end{bmatrix} \begin{bmatrix} 87 \\ 583 \end{bmatrix} \\ &= \frac{1}{825} \begin{bmatrix} (385)(87) + (-55)(583) \\ (-55)(87) + (10)(583) \end{bmatrix} \\ &= \frac{1}{825} \begin{bmatrix} 33495 - 32065 \\ -4785 + 5830 \end{bmatrix} \\ &= \frac{1}{825} \begin{bmatrix} 1430 \\ 1045 \end{bmatrix} = \begin{bmatrix} 1430/825 \\ 1045/825 \end{bmatrix} = \begin{bmatrix} 26/15 \\ 19/15 \end{bmatrix} \end{aligned}$$

สรุป 1b: ได้ค่าสัมประสิทธิ์ดังนี้:


- **Intercept (α)** = $\frac{26}{15} \approx 1.7333$
- **Slope (β)** = $\frac{19}{15} \approx 1.2667$

1c) สมการ Fitted Line

นำค่า α และ β ที่คำนวณได้ไปแทนในสมการ $\hat{Y} = \alpha + \beta X$

สรุป 1c: สมการ Fitted Line คือ:

$$\hat{Y} = 1.7333 + 1.2667 X$$



รูปที่ 1: Scatter Plot แสดงความสัมพันธ์ระหว่างโฆษณากับยอดขาย พร้อมเส้น Fitted Line

$$\hat{Y} = 1.7333 + 1.2667 X$$

Task 2: Interpret the Results

2a) ความหมายของ Slope และ Intercept

ความหมายของ Slope ($\beta \approx 1.2667$):

Slope บ่งบอกว่ายอดขาย (Sales) ถูกคาดการณ์ว่าจะเพิ่มตามค่าโฆษณา (Advertising) ที่เพิ่มขึ้น นั่นคือ ทุก ๆ \$1,000 ของ advertising ที่เพิ่มขึ้น จะทำให้ยอดขาย (Sales) เพิ่มขึ้นประมาณ **1,267 หน่วย** ค่านี้เป็นความสัมพันธ์เชิงสถิติ (association) ไม่ใช่การพิสูจน์ว่าโฆษณาเป็นสาเหตุ (causation) ของยอดขายที่เพิ่มขึ้น

ความหมายของ Intercept ($\alpha \approx 1.7333$):

จุดตัดแกน Y บ่งบอกยอดขายที่คาดการณ์ไว้เมื่อไม่มีต้นทุนค่าโฆษณา กล่าวคือ ถ้าบริษัทไม่ทำโฆษณาเลย ($X = 0$) จะสามารถคาดการณ์ยอดขายได้ประมาณ **1,733 หน่วย**

2b) Predict ยอดขายเมื่องบโฆษณา = \$12,000

แทน $X = 12$ ลงในสมการที่ได้:

$$\hat{Y} = 1.7333 + 1.2667(12)$$

$$\hat{Y} = 1.7333 + 15.2004$$

$$\hat{Y} \approx 16.9333$$

สรุป 2b: ถ้าต้นทุนในการโฆษณาคือ \$12,000 คาดการณ์ยอดขายได้ประมาณ **16.93 พันหน่วย** (ประมาณ 16,933 หน่วย)

ข้อควรระวัง: $X = 12$ อยู่นอกช่วงข้อมูลที่ใช้ fit โมเดล (ค่าสูงสุดใน dataset คือ $X = 10$) การทำนายนี้จึงเป็น **extrapolation** ซึ่งโมเดลไม่สามารถยืนยันได้ว่าความสัมพันธ์เชิงเส้นยังคงดำเนินต่อไปที่ระดับนี้

Task 3: Model Evaluation

3a) คำนวณ R-squared (R^2)

R^2 วัดความเหมาะสมของแบบจำลอง (Goodness of fit) นิยามเป็น:

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

โดย:

- $SS_{\text{res}} = \sum (Y_i - \hat{Y}_i)^2$
- $SS_{\text{tot}} = \sum (Y_i - \bar{Y})^2$

คำนวณ: (โดย $\bar{Y} = 8.7$)

i	X_i	Y_i	$\hat{Y}_i = 1.7333 + 1.2667X_i$	$e_i = Y_i - \hat{Y}_i$	e_i^2	$(Y_i - \bar{Y})^2$
1	3.0	6.0	5.5333	0.4667	0.2178	7.2900
2	5.0	9.0	8.0667	0.9333	0.8711	0.0900
3	2.0	4.0	4.2667	-0.2667	0.0711	22.0900
4	7.0	10.0	10.6000	-0.6000	0.3600	1.6900
5	8.0	12.0	11.8667	0.1333	0.0178	10.8900
6	1.0	3.0	3.0000	0.0000	0.0000	32.4900
7	4.0	7.0	6.8000	0.2000	0.0400	2.8900
8	6.0	8.0	9.3333	-1.3333	1.7778	0.4900
9	9.0	13.0	13.1333	-0.1333	0.0178	18.4900
10	10.0	15.0	14.4000	0.6000	0.3600	39.6900
Σ					3.7333	136.1000

Listing 2: Computing R^2 from residuals

```

1 Y_hat      = alpha + beta * X
2 residuals  = Y - Y_hat
3 SS_res     = np.sum(residuals**2)           # 3.7333
4 SS_tot     = np.sum((Y - Y_bar)**2)         # 136.1
5 R2         = 1 - SS_res / SS_tot
6
7 print(f"SS_res = {SS_res:.4f}")
8 print(f"SS_tot = {SS_tot:.4f}")
9 print(f"R^2    = {R2:.6f}")
10 print(f"Residual mean = {residuals.mean():.6f}")
11 print(f"Residual std  = {residuals.std(ddof=1):.6f}")

```

```

SS_res = 3.7333
SS_tot = 136.1000
R^2     = 0.972569
Residual mean = 0.000000
Residual std  = 0.644061

```

จากตาราง: $SS_{\text{res}} = 3.7333$, $SS_{\text{tot}} = 136.1000$

แทนค่า:

$$R^2 = 1 - \frac{3.7333}{136.10} = 1 - 0.0274 = 0.9726$$


สรุป 3a: $R^2 \approx 0.9726$ หรือประมาณ 97.26%

3b) ตีความค่า R-squared


สรุป 3b: ค่า R-squared ที่ 0.9726 หมายความว่า ประมาณ **97.26%** ของการเปลี่ยนแปลงของยอดขาย (Sales) สามารถถูกอธิบายได้ด้วยงบโฆษณา (Advertising Budget) จากตาราง residuals ข้างต้น พบว่า $\bar{e} = 0$ (*residual mean* เท่ากับศูนย์พอดี แสดงว่าโมเดลไม่มี *bias*) โดย Standard Deviation ของ residuals อยู่ที่ $s_e = 0.6441$ พันหน่วย (เทียบกับค่าเฉลี่ยได้ดี เพราะ residual สูงสุดใน dataset คือ $|e_8| = 1.33$)

สิ่งที่ R^2 สูงไม่ได้บ่งชี้: ว่างบโฆษณาเป็นสาเหตุของยอดขาย หรือรับประกันว่าโมเดลจะพยากรณ์ได้ดีเสมอในอนาคต

Residual Diagnostics



รูปที่ 2: Residual Diagnostics Panel — (top-left) Residuals vs Fitted แสดงว่า residuals ไม่มีรูปแบบชัดเจนรอบเส้นศูนย์; (top-right) Residual Distribution การกระจายใกล้เคียง Normal; (bottom-left) Q-Q Plot ยืนยันความเป็น Normal; (bottom-right) Scale-Location ไม่พบ Heteroscedasticity



รูปที่ 3: Actual vs Fitted Sales — จุดทุกจุดอยู่ใกล้เส้น Perfect Fit ($Y = \hat{Y}$) ด้านแดงพระ แสดงว่าโมเดล fit ข้อมูลได้ดี

สรุปผลลัพธ์

ข้อ	คำตอบ
1a	ระบบสมการ $10\alpha + 55\beta = 87$ และ $55\alpha + 385\beta = 583$
1b	Intercept (α) ≈ 1.7333 , Slope (β) ≈ 1.2667
1c	สมการ Fitted Line: $\hat{Y} = 1.7333 + 1.2667X$
2a	Slope: เพิ่มงบประมาณ \$1,000 ทำให้ยอดขายเพิ่ม 1,267 หน่วย Intercept: หากไม่มีงบประมาณเลย ยอดขายคาดการณ์คือ 1,733 หน่วย
2b	เมื่องบประมาณ = \$12,000 ค่าการณียอดขายได้ประมาณ 16,933 หน่วย
3a	$R^2 \approx 0.9726$ (97.26%)
3b	97.26% ของยอดขายสามารถอธิบายได้ด้วยงบประมาณ (โมเดลมีความเหมาะสมดีเยี่ยม)

โค้ดสำหรับคำนวณและสร้างกราฟทั้งหมดอยู่ใน Assignment_1_OLS.ipynb