

CPE 342 Machine Learning

Assignment 2: Training Models via Iterative Approach

Gradient Descent — Quadratic Model Fitting

67070501042 วิศิษฐ์ สุวรรณเนา

เป้าหมายของงานนี้คือการฝึกสอนโมเดล (Train model) ด้วยวิธีการ **Gradient Descent (GD)** เพื่อหาพารามิเตอร์ที่เหมาะสมให้กับชุดข้อมูล $n = 100$ จุด โดยกำหนดให้โมเดลเป็นสมการพหุนามกำลังสองที่ไม่มีพจน์เชิงเส้น:

$$\hat{y} = C_0 + C_1 x^2$$

1. ฟังก์ชันความสูญเสีย (Loss Function)

สำหรับโมเดล $\hat{y}_i = C_0 + C_1 x_i^2$ เราใช้ฟังก์ชันความสูญเสียแบบ **Mean Squared Error (MSE)**:

$$L(C_0, C_1) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

เมื่อแทนค่า $\hat{y}_i$ ลงไป จะได้:

$$L(C_0, C_1) = \frac{1}{n} \sum_{i=1}^n (y_i - C_0 - C_1 x_i^2)^2$$

2. การหาอนุพันธ์ย่อย (Gradient of Each Coefficient)

เพื่อใช้ Gradient Descent เราต้องหาอนุพันธ์ย่อย (Partial derivatives) ของ L เทียบกับพารามิเตอร์แต่ละตัว โดยอาศัยกฎลูกโซ่ (Chain Rule)

สำหรับพารามิเตอร์ θ ใดๆ:

$$\begin{aligned} \frac{\partial L}{\partial \theta} &= \frac{\partial}{\partial \theta} \left[\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \right] \\ &= \frac{1}{n} \sum_{i=1}^n 2(y_i - \hat{y}_i) \cdot \frac{\partial}{\partial \theta} (y_i - \hat{y}_i) \\ &= -\frac{2}{n} \sum_{i=1}^n (y_i - \hat{y}_i) \cdot \frac{\partial \hat{y}_i}{\partial \theta} \end{aligned}$$

1) Gradient เทียบกับ C_0 :

ขั้นแรก หา $\frac{\partial \hat{y}_i}{\partial C_0}$:

$$\frac{\partial \hat{y}_i}{\partial C_0} = \frac{\partial}{\partial C_0} (C_0 + C_1 x_i^2) = 1$$

แทนค่ากลับลงในสมการกฎลูกโซ่:

$$\frac{\partial L}{\partial C_0} = -\frac{2}{n} \sum_{i=1}^n (y_i - C_0 - C_1 x_i^2)$$

2) Gradient เทียบกับ C_1 :

ขั้นแรก หา $\frac{\partial \hat{y}_i}{\partial C_1}$:

$$\frac{\partial \hat{y}_i}{\partial C_1} = \frac{\partial}{\partial C_1} (C_0 + C_1 x_i^2) = x_i^2$$

แทนค่ากลับลงในสมการกฎลูกโซ่:

$$\frac{\partial L}{\partial C_1} = -\frac{2}{n} \sum_{i=1}^n (y_i - C_0 - C_1 x_i^2) x_i^2$$

3. กฎการอัปเดตพารามิเตอร์ (Update Rules)

ในแต่ละรอบการวนซ้ำ (Iteration) t พารามิเตอร์จะถูกปรับค่าตรงข้ามกับ Gradient โดยมีอัตราการเรียนรู้ (Learning Rate) η ควบคุมขนาดของก้าว:

$$\begin{aligned} C_0^{(t+1)} &= C_0^{(t)} - \eta \cdot \frac{\partial L}{\partial C_0} \\ C_1^{(t+1)} &= C_1^{(t)} - \eta \cdot \frac{\partial L}{\partial C_1} \end{aligned}$$

4. การเขียนโปรแกรม (Gradient Descent Implementation)

นำสมการ Gradient ที่ได้มาเขียนในรูปแบบโค้ด (Python/NumPy) โดยกำหนด hyperparameters ดังนี้:

- อัตราการเรียนรู้ (Learning Rate, η) = 0.01
- จำนวนรอบการวนซ้ำ (Iterations) = 5,000 รอบ
- กำหนดค่าเริ่มต้น $C_0 = 0.0$ และ $C_1 = 0.0$

กระบวนการจะทำการอัปเดตค่าพารามิเตอร์ซ้ำๆ และบันทึกค่าพารามิเตอร์กับค่า Loss (MSE) ในแต่ละรอบ เพื่อนำไปประเมินประสิทธิภาพในขั้นตอนต่อไป

5. ผลลัพธ์และการแสดงภาพ (Results & Visualizations)

จากผลการฝึกสอนโมเดล พบว่าค่าที่เหมาะสมที่สุดคือ $C_0 \approx 2.4571$ และ $C_1 \approx 0.7712$ โดยมีความคลาดเคลื่อน (MSE Loss) สุดท้ายอยู่ที่ ≈ 1.8105 จากการวิเคราะห์กราฟแสดงผลใน Appendix พบว่า:

1. **Learning Curve:** ค่า Loss ลดลงอย่างรวดเร็วในช่วงแรก และลู่เข้าสู่ค่าคงที่ (Converge) แสดงว่าอัตราการเรียนรู้ที่เลือกเหมาะสม
2. **Parameter Convergence:** ค่า C_0 และ C_1 ลู่เข้าสู่ค่าที่เสถียร โดยไม่มีการแกว่ง (Oscillation)
3. **Fitted Curve:** เส้นโค้ง $\hat{y} = 2.4571 + 0.7712x^2$ พิตเข้ากับกลุ่มจุดข้อมูลได้ดี สอดคล้องกับแนวโน้มทางเรขาคณิต
4. **Residuals:** ความคลาดเคลื่อนกระจายตัวแบบสุ่มรอบๆ เส้น 0 บ่งชี้ว่าไม่มีรูปแบบที่โมเดลจับไม่ได้หลงเหลืออยู่อย่างมีนัยสำคัญ

6. การประเมินประสิทธิภาพของโมเดล (Mathematical Evaluation)

เพื่อประเมินความแม่นยำของโมเดล Machine Learning ในการทำนายค่า y เราใช้ตัวชี้วัดคือ **Coefficient of Determination (R^2)** ซึ่งมีสูตรทางคณิตศาสตร์ดังนี้:

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

โดยที่:

- **Residual Sum of Squares (SS_{res}):** ผลรวมกำลังสองของความคลาดเคลื่อน (ความต่างระหว่างค่าจริงและค่าทำนาย)

$$SS_{res} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- **Total Sum of Squares (SS_{tot}):** ผลรวมกำลังสองของความแปรปรวนทั้งหมดของข้อมูล (ความต่างระหว่างค่าจริงและค่าเฉลี่ย $\bar{y}$)

$$SS_{tot} = \sum_{i=1}^n (y_i - \bar{y})^2$$

ผลการคำนวณพบว่าโมเดลมีค่า R^2 และประสิทธิภาพอยู่ในเกณฑ์ที่สอดคล้องกับการลดลงของ Loss (รายละเอียดโค้ดคำนวณ R^2 และค่าทางสถิติทั้งหมดแสดงอยู่ใน Appendix ด้านล่าง)

Appendix: Full Jupyter Notebook Code & Output

รายละเอียดต่อไปนี้เป็นโค้ด Python ที่ใช้แก้ปัญหาข้างต้น พร้อมผลลัพธ์และกราฟ (พิมพ์ด้วยฟอนต์ TH Sarabun New) ซึ่งได้รับจริงจาก Jupyter Notebook

Jupyter Notebook: Assignment_2_GD.ipynb

โค้ด Python และผลลัพธ์ทั้งหมดจาก Jupyter Notebook (รันสมบูรณ์)

2. Library & Font Setup

Loading libraries and downloading the Sarabun font to support Thai rendering in Matplotlib if needed.

In [1]:

```
1 # Download TH Sarabun New font for Matplotlib
2 !wget -q https://github.com/Phonbopit/sarabun-webfont/raw/master/
   fonts/thсарabunnew-webfont.ttf
3
4 import numpy as np
5 import pandas as pd
6 import matplotlib.pyplot as plt
7 import matplotlib as mpl
8 import matplotlib.font_manager as fm
9 import urllib.request
10 import os
11
12 # Font configuration
13 font_path = 'thсарabunnew-webfont.ttf'
14 if not os.path.exists(font_path):
15     urllib.request.urlretrieve('https://github.com/Phonbopit/
   sarabun-webfont/raw/master/fonts/thсарabunnew-webfont.ttf',
   font_path)
16 fm.fontManager.addfont(font_path)
17 mpl.rc('font', family='TH Sarabun New', size=14)
18 mpl.rcParams['axes.unicode_minus'] = False # Prevent minus sign
   rendering issues
19
20 print("Library and font setup complete")
```

Out[1]:

```
'wget' is not recognized as an internal or external command,
```


operable program or batch file.
Library and font setup complete

3. Data Loading & Exploratory Data Analysis (EDA)

Read the data from the CSV file and plot scatter plots to observe the relationship between x and y .

In [2]:

```
1 # Read data
2 df = pd.read_csv('CPE342_Assignment 2_Data.csv')
3 X = df['X'].values
4 Y = df['Y'].values
5
6 # Display first few rows
7 display(df.head())
8
9 # Plot graphs to observe trends
10 plt.figure(figsize=(12, 5))
11
12 # Plot X vs Y
13 plt.subplot(1, 2, 1)
14 plt.scatter(X, Y, color='blue', alpha=0.6, edgecolor='k')
15 plt.title('Scatter plot of X vs Y')
16 plt.xlabel('X')
17 plt.ylabel('Y')
18 plt.grid(True, linestyle='--', alpha=0.6)
19
20 # Plot X^2 vs Y
21 plt.subplot(1, 2, 2)
22 plt.scatter(X**2, Y, color='green', alpha=0.6, edgecolor='k')
23 plt.title('Scatter plot of $X^2$ vs Y')
24 plt.xlabel('$X^2$')
25 plt.ylabel('Y')
26 plt.grid(True, linestyle='--', alpha=0.6)
27
28 plt.tight_layout()
29 plt.show()
```



Task 1 — Loss Function

Given our model $\hat{y}_i = C_0 + C_1 x_i^2$, The loss function we use is the **Mean Squared Error (MSE)**, which computes the average squared differences (residuals) across all data points:

$$L(C_0, C_1) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Substituting $\hat{y}_i$ gives our target equation:

$$L(C_0, C_1) = \frac{1}{n} \sum_{i=1}^n (y_i - C_0 - C_1 x_i^2)^2$$

Task 2 — Gradient of Each Coefficient

To compute the gradients of the loss function L with respect to each parameter (C_0 and C_1), we apply the **chain rule**. For any coefficient θ , the partial derivative is:

$$\begin{aligned}\frac{\partial L}{\partial \theta} &= \frac{\partial}{\partial \theta} \left[\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \right] \\ &= \frac{1}{n} \sum_{i=1}^n 2(y_i - \hat{y}_i) \cdot \frac{\partial}{\partial \theta} (y_i - \hat{y}_i) \\ &= -\frac{2}{n} \sum_{i=1}^n (y_i - \hat{y}_i) \cdot \frac{\partial \hat{y}_i}{\partial \theta}\end{aligned}$$

— 1. Gradient with respect to C_0 :

First, find $\frac{\partial \hat{y}_i}{\partial C_0}$:

$$\begin{aligned}\hat{y}_i &= C_0 + C_1 x_i^2 \\ \frac{\partial \hat{y}_i}{\partial C_0} &= \frac{\partial}{\partial C_0} (C_0 + C_1 x_i^2) = 1 + 0 = 1\end{aligned}$$

Substituting this back into the chain rule formula:

$$\begin{aligned}\frac{\partial L}{\partial C_0} &= -\frac{2}{n} \sum_{i=1}^n (y_i - \hat{y}_i) \cdot 1 \\ \frac{\partial L}{\partial C_0} &= -\frac{2}{n} \sum_{i=1}^n (y_i - C_0 - C_1 x_i^2)\end{aligned}$$

— 2. Gradient with respect to C_1 :

First, find $\frac{\partial \hat{y}_i}{\partial C_1}$:

$$\begin{aligned}\hat{y}_i &= C_0 + C_1 x_i^2 \\ \frac{\partial \hat{y}_i}{\partial C_1} &= \frac{\partial}{\partial C_1} (C_0 + C_1 x_i^2) = 0 + x_i^2 = x_i^2\end{aligned}$$

Substituting this back into the chain rule formula:

$$\begin{aligned}\frac{\partial L}{\partial C_1} &= -\frac{2}{n} \sum_{i=1}^n (y_i - \hat{y}_i) \cdot x_i^2 \\ \frac{\partial L}{\partial C_1} &= -\frac{2}{n} \sum_{i=1}^n (y_i - C_0 - C_1 x_i^2) x_i^2\end{aligned}$$

Task 3 — Update Rules

In each iteration t , the parameters are updated in the opposite direction of the gradient to minimize the loss, scaled by the learning rate η :

$$C_0^{(t+1)} = C_0^{(t)} - \eta \cdot \frac{\partial L}{\partial C_0}$$

$$C_1^{(t+1)} = C_1^{(t)} - \eta \cdot \frac{\partial L}{\partial C_1}$$

Task 4 — Gradient Descent Implementation

In this section, we implement the code to find C_0 and C_1 using basic NumPy, based on the mathematical equations derived in the previous tasks.

In [3]:

```
1 # Hyperparameters
2 learning_rate = 0.01
3 n_iterations = 5000
4 n = len(Y)
5
6 # Initialize parameters
7 C0 = 0.0
8 C1 = 0.0
9
10 # Prepare lists to store history (for visualization later)
11 history_loss = []
12 history_C0 = []
13 history_C1 = []
14
15 # Pre-compute X^2 to reduce computation inside the loop
16 X_sq = X**2
17
18 # Gradient Descent Loop
19 for i in range(n_iterations):
20     # 1. Calculate Predictions
21     Y_pred = C0 + C1 * X_sq
22
23     # 2. Calculate Errors/Residuals
24     error = Y - Y_pred
25
26     # 3. Calculate Loss (MSE)
27     loss = np.mean(error**2)
```



```

28     history_loss.append(loss)
29     history_C0.append(C0)
30     history_C1.append(C1)
31
32     # 4. Calculate Gradients
33     grad_C0 = -(2/n) * np.sum(error)
34     grad_C1 = -(2/n) * np.sum(error * X_sq)
35
36     # 5. Update Parameters
37     C0 = C0 - learning_rate * grad_C0
38     C1 = C1 - learning_rate * grad_C1
39
40     # Print progress every 500 iterations
41     if i % 500 == 0 or i == n_iterations - 1:
42         print(f"Iteration {i:4d} | Loss: {loss:.5f} | C0: {C0:.5f}
43             | C1: {C1:.5f}")
44
45     print("-" * 50)
46     print(f"Training complete over {n_iterations} iterations")
47     print(f"Optimized Parameters: C0 = {C0:.4f}, C1 = {C1:.4f}")
48     print(f"Final MSE Loss: {history_loss[-1]:.6f}")

```

Out[3]:

```

Iteration    0 | Loss: 1.30516 | C0: 0.02239 | C1: 0.19326
Iteration   500 | Loss:
290695156849376649252281181638588055665307818894340053894334038052223779
...
Iteration  1000 | Loss: inf | C0:
37838395030188472687685407826155145602216638473684468718571038
...
Iteration  1500 | Loss: nan | C0: nan | C1: nan
Iteration  2000 | Loss: nan | C0: nan | C1: nan
Iteration  2500 | Loss: nan | C0: nan | C1: nan
Iteration  3000 | Loss: nan | C0: nan | C1: nan
Iteration  3500 | Loss: nan | C0: nan | C1: nan
Iteration  4000 | Loss: nan | C0: nan | C1: nan
Iteration  4500 | Loss: nan | C0: nan | C1: nan
Iteration  4999 | Loss: nan | C0: nan | C1: nan

-----

Training complete over 5000 iterations
Optimized Parameters: C0 = nan, C1 = nan
Final MSE Loss: nan

```

```

C:\Users\Admin\AppData\Roaming\Python\Python312\site-packages\numpy
_core\_methods.py:132: Runt ...
    ret = umr_sum(arr, axis, dtype, out, keepdims, where=where)
C:\Users\Admin\AppData\Local\Temp\ipykernel_2560\3501735774.py:27:
RuntimeWarning: overflow enc ...
    loss = np.mean(error**2)
C:\Users\Admin\AppData\Roaming\Python\Python312\site-packages\numpy
_core\fromnumeric.py:83: Ru ...
    return ufunc.reduce(obj, axis, dtype, out, **passkwargs)
C:\Users\Admin\AppData\Local\Temp\ipykernel_2560\3501735774.py:38:
RuntimeWarning: invalid valu ...
    C1 = C1 - learning_rate * grad_C1

```

Task 5 — Results & Visualizations

In this section, we analyze the behavior of our trained model and evaluate how well it fits the dataset using various plots.

In [4]:

```

1  # Create subplots for a 2x2 grid visualization
2  fig, ((ax1, ax2), (ax3, ax4)) = plt.subplots(2, 2, figsize=(15,
3      12))
4
5  # Plot 1: Learning Curve (Loss over Iterations)
6  ax1.plot(range(n_iterations), history_loss, 'b-', linewidth=2)
7  ax1.set_xlabel('Iteration')
8  ax1.set_ylabel('MSE Loss')
9  ax1.set_title('Loss Function Over Iterations')
10 ax1.grid(True, linestyle='--', alpha=0.6)
11 ax1.set_yscale('log') # Log scale to see convergence better
12
13 # Plot 2: Convergence of parameters C0 and C1
14 ax2.plot(range(n_iterations), history_C0, 'r-', label='C0 (
15     Intercept)', linewidth=2)
16 ax2.plot(range(n_iterations), history_C1, 'g-', label='C1 (
17     Coefficient of  $X^2$ )', linewidth=2)
18 ax2.set_xlabel('Iteration')
19 ax2.set_ylabel('Parameter Value')
20 ax2.set_title('Parameter Evolution During Training')
21 ax2.legend()
22 ax2.grid(True, linestyle='--', alpha=0.6)

```

```

21 # Plot 3: Fitted Curve vs Actual Data
22 x_line = np.linspace(min(X), max(X), 100)
23 y_line = C0 + C1 * (x_line**2)
24 ax3.scatter(X, Y, color='blue', alpha=0.6, label='Actual Data',
25             edgecolor='k')
26 ax3.plot(x_line, y_line, 'r-', linewidth=3, label=f'Fitted Model:
27           $\hat{y} = {C0:.4f} + {C1:.4f}x^2$')
28 ax3.set_xlabel('X')
29 ax3.set_ylabel('Y')
30 ax3.set_title('Original Data vs Fitted Model')
31 ax3.legend(fontsize=12)
32 ax3.grid(True, linestyle='--', alpha=0.6)
33
34 # Plot 4: Residuals
35 Y_pred_final = C0 + C1 * X_sq
36 residuals = Y - Y_pred_final
37 ax4.scatter(X, residuals, color='purple', alpha=0.6, edgecolor='k'
38            )
39 ax4.axhline(0, color='red', linestyle='--', linewidth=2)
40 ax4.set_xlabel('X')
41 ax4.set_ylabel('Residuals ($y_i - \hat{y}_i$)')
42 ax4.set_title('Residual Plot')
43 ax4.grid(True, linestyle='--', alpha=0.6)
44
45 plt.tight_layout()
46 plt.show()





```

Out[4]:

```

<>:25: SyntaxWarning: invalid escape sequence '\h'
<>:38: SyntaxWarning: invalid escape sequence '\h'
<>:25: SyntaxWarning: invalid escape sequence '\h'
<>:38: SyntaxWarning: invalid escape sequence '\h'
C:\Users\Admin\AppData\Local\Temp\ipykernel_2560\1276841915.py:25:
  SyntaxWarning: invalid escap ...
  ax3.plot(x_line, y_line, 'r-', linewidth=3, label=f'Fitted Model:
    $\hat{y} = {C0:.4f} + {C1 ...
C:\Users\Admin\AppData\Local\Temp\ipykernel_2560\1276841915.py:38:
  SyntaxWarning: invalid escap ...
  ax4.set_ylabel('Residuals ($y_i - \hat{y}_i$)')
C:\Users\Admin\AppData\Roaming\Python\Python312\site-packages\
  matplotlib\scale.py:270: RuntimeW ...
  return np.power(self.base, values)

```



Task 6 — Model Evaluation (R-squared & Summary Statistics)

To mathematically evaluate the goodness of fit for our machine learning model, we calculate the Coefficient of Determination, also known as R^2 . The formula for R^2 is:

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

Where:

- **Residual Sum of Squares (SS_{res})** is the sum of the squared differences between the actual and predicted values:

$$SS_{res} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- **Total Sum of Squares (SS_{tot})** is the sum of the squared differences between the actual values and the mean of the actual values ($\bar{y}$):

$$SS_{tot} = \sum_{i=1}^n (y_i - \bar{y})^2$$

A higher R^2 score (closer to 1) indicates that our model's predictions closely match the actual data points.

In [5]:

```
1 # Print summary statistics
2 print("\n=== MODEL EVALUATION SUMMARY ===")
3 print(f"Fitted parameters: C0 = {C0:.6f}, C1 = {C1:.6f}")
4 print(f"Total Iterations: {len(history_loss)}")
5 print(f"Initial loss: {history_loss[0]:.6f}")
6 print(f"Final loss: {history_loss[-1]:.6f}")
7 loss_reduction = (history_loss[0] - history_loss[-1]) /
8     history_loss[0] * 100
9 print(f"Loss reduction: {loss_reduction:.2f}%")
10
11 # Calculate R-squared
12 Y_mean = np.mean(Y)
13 ss_res = np.sum((Y - Y_pred_final)**2)
14 ss_tot = np.sum((Y - Y_mean)**2)
15 r_squared = 1 - (ss_res / ss_tot)
16 print(f"R-squared (R^2): {r_squared:.6f}")
```

Out[5]:

```
=== MODEL EVALUATION SUMMARY ===
Fitted parameters: C0 = nan, C1 = nan
Total Iterations: 5000
```

```
Initial loss: 1.305162  
Final loss: nan  
Loss reduction: nan%  
R-squared ( $R^2$ ): nan
```