

CPE 342 Machine Learning
Assignment 3: Regression — Survival Analysis
Activity: Estimating Customer Lifetime on Telco Churn Dataset
67070501042 วิชาสถิติสุพรรณนา (WISIT SUWANNAO)

1 Problem Overview & Objectives (บทนำและภาพรวมของปัญหา)

ในงานมอบหมายส่วนของ Activity นี้ เราศึกษาและวิเคราะห์พฤติกรรมการคงอยู่และการยกเลิกบริการของลูกค้า (Customer Retention & Churn Dynamics) โดยประยุกต์ใช้ระเบียบวิธี การวิเคราะห์การอยู่รอด (Survival Analysis) ด้วยตัวประมาณค่าแบบนอนพารามิเตอร์ **Kaplan-Meier Estimator** บนชุดข้อมูล Telco-Churn.csv ซึ่งประกอบด้วยข้อมูลลูกค้ารวม $N = 7,043$ ราย

1.1 วัตถุประสงค์หลักของการวิเคราะห์

1. เพื่อสร้างตัวแปรระยะเวลาการใช้บริการ $T = \text{tenure}$ (หน่วย: เดือน) และตัวบ่งชี้การเกิดเหตุการณ์ยกเลิกบริการ $E = \mathbb{I}(\text{Churn} == \text{'Yes'})$
2. เพื่อจัดการปัญหา ข้อมูลถูกจำกัดช่วงทางขวา (Right-Censoring) สำหรับลูกค้าที่ยังคงใช้บริการอยู่ ณ ปัจจุบัน ($E = 0$)
3. เพื่อประมาณค่าฟังก์ชันการอยู่รอดของประชากรโดยรวม $\hat{S}(t)$ พร้อมคำนวณช่วงความเชื่อมั่น 95% ด้วยสูตรของ Greenwood
4. เพื่อเปรียบเทียบวิธีการอยู่รอดและความเสี่ยงในการยกเลิกบริการระหว่างช่องทางการชำระเงินทั้ง 4 รูปแบบ (PaymentMethod): **Electronic check**, **Mailed check**, **Bank transfer (automatic)** และ **Credit card (automatic)**
5. เพื่อทดสอบนัยสำคัญทางสถิติด้วยการทดสอบ **Log-Rank Test** (ทั้งแบบ Multivariate และ Pairwise) เพื่อยืนยันความแตกต่างของเส้นโค้งการอยู่รอดอย่างมีนัยสำคัญ ($p < 0.001$)
6. เพื่อนำผลลัพธ์เชิงปริมาณและค่าความน่าจะเป็น ณ ช่วงเวลาสำคัญ ($t = 12, 24, 36, 48, 60, 72$ เดือน) ไป แพล ผล เชิง ธุรกิจ และ เสนอ แนวทาง ลด อัตรา การ ยกเลิก บริการ (Churn Mitigation Strategy)

2 Theoretical Framework (กรอบทฤษฎีและคณิตศาสตร์ จาก Lecture 4)

2.1 ข้อจำกัดของ Regression ทั่วไปกับข้อมูล Time-to-Event

ในการวิเคราะห์ข้อมูลระยะเวลาจนกระทั่งเกิดเหตุการณ์ (Time-to-Event Data) เช่น การยกเลิกบริการของลูกค้า การใช้สมการถดถอยเชิงเส้น (Linear Regression) หรือ Logistic Regression ทั่วไปมีข้อจำกัดร้ายแรงดังนี้ (อิงตาม Lecture 4 หน้า 27–33):

- **การติดปัญหา Right-Censoring:** ลูกค้าส่วนใหญ่ (73.46%) ยังไม่ยกเลิกบริการในวันที่เก็บข้อมูล เราจึงรู้ว่าระยะเวลาของลูกค้าเหล่านี้มีค่าน้อยเท่ากับ t ($T \geq t$) แต่ไม่รู้เวลาสิ้นสุดจริง หากตัดข้อมูลเหล่านี้ทิ้งจะเกิดภาวะความลำเอียงจากการคัดออก (Selection Bias) หรือหากนับว่า t คือเวลาสิ้นสุด โมเดลจะประเมินอายุขัยของลูกค้าต่ำกว่าความเป็นจริง (Underestimation)
- **การแจกแจงแบบเบ้และค่าเป็นบวกเสมอ:** ตัวแปรเวลา $T \geq 0$ มีลักษณะการแจกแจงแบบเบ้ขวา (Positive Skewness) ซึ่งละเมิดข้อสมมติฐาน Normal Distribution ของ Ordinary Least Squares (OLS)
- **Logistic Regression ขาดมิติของเวลา:** Logistic Regression สนใจเพียงแค่ว่าเกิดเหตุการณ์หรือไม่ ณ จุดสิ้นสุดการทดลอง แต่ไม่สามารถตอบได้ว่าลูกค้ายกเลิกบริการที่เวลาใด หรือความน่าจะเป็นที่จะอยู่รอดผ่านปีที่ 1 หรือปีที่ 2 เป็นเท่าใด

2.2 นิยามทางคณิตศาสตร์ของฟังก์ชันการอยู่รอดและฟังก์ชันความเสี่ยง

กำหนดให้ $T \geq 0$ เป็นตัวแปรสุ่มชนิดต่อเนื่องแทนระยะเวลาจนกว่าจะเกิดเหตุการณ์ โดยมีฟังก์ชันความหนาแน่นความน่าจะเป็น $f(t)$ และฟังก์ชันการแจกแจงสะสม $F(t) = P(T < t)$

2.2.1 1. ฟังก์ชันการอยู่รอด (Survival Function: $S(t)$)

ฟังก์ชัน $S(t)$ คือความน่าจะเป็นที่ลูกค้ารายหนึ่งจะยังคงใช้บริการอยู่เกินกว่าเวลา t

$$S(t) = P(T \geq t) = 1 - F(t) = \int_t^\infty f(u) du \quad (1)$$

โดยมีคุณสมบัติทางคณิตศาสตร์คือ: $S(0) = 1$ (ณ จุดเริ่มต้น ลูกค้าทุกคนยังอยู่), $S(\infty) = 0$ (เมื่อเวลาผ่านไปไม่สิ้นสุด ทุกคนจะเกิดเหตุการณ์) และ $S(t)$ เป็นฟังก์ชันลดลงทางเดียวหรือไม่เพิ่มขึ้น (Monotonically Non-increasing)

2.2.2 2. ฟังก์ชันความเสี่ยง (Hazard Function: $\lambda(t)$ หรือ $h(t)$)

ฟังก์ชัน $\lambda(t)$ แทนอัตราความเสี่ยงขณะใดขณะหนึ่ง (Instantaneous Failure Rate) ที่ลูกค้าซึ่งรอดชีวิตมาจนถึงเวลา t จะยกเลิกบริการในช่วงเวลาถัดไปสั้น ๆ Δt

$$\lambda(t) = \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t \mid T \geq t)}{\Delta t} = \frac{f(t)}{S(t)} = -\frac{d}{dt} \ln S(t) \quad (2)$$

2.2.3 3. ฟังก์ชันความเสี่ยงสะสม (Cumulative Hazard Function: $\Lambda(t)$)

คือผลรวมสะสมของความเสี่ยงตั้งแต่จุดเริ่มต้นจนถึงเวลา t

$$\Lambda(t) = \int_0^t \lambda(u) du = -\ln S(t) \iff S(t) = \exp(-\Lambda(t)) \quad (3)$$

2.3 ตัวประมาณค่า Kaplan-Meier (Product-Limit Estimator)

ในการประมาณค่า $S(t)$ แบบนอนพารามิเตอร์โดยไม่สมมติรูปแบบการแจกแจงล่วงหน้า Kaplan & Meier (1958) ได้พัฒนาสูตรผลคูณสะสม (Product-Limit Formula):

$$\hat{S}(t) = \prod_{t_i \leq t} \left(1 - \frac{d_i}{n_i}\right) \quad (4)$$

เมื่อ:

- $t_1 < t_2 < \dots < t_k$ คือลำดับเวลาที่เกิดเหตุการณ์ยกเลิกบริการจริง
- d_i คือจำนวนลูกค้าที่เกิดเหตุการณ์ยกเลิกบริการ ณ เวลา t_i
- n_i คือจำนวนลูกค้าที่ยังคงมีความเสี่ยง (Risk Set) ณ จุดเวลาก่อน t_i (n_i รวมทั้งผู้ที่กำลังจะยกเลิกและผู้ที่ถูกเซนเซอร์หลังเวลา t_i)

ช่วง ความ เชื่อ มั่น 95% คำนวณ ผ่าน ความ แปรปรวน ของ Greenwood (Greenwood's Formula):

$$\widehat{\text{Var}}(\hat{S}(t)) = \hat{S}(t)^2 \sum_{t_i \leq t} \frac{d_i}{n_i(n_i - d_i)} \quad (5)$$

$$95\% \text{ Confidence Interval: } \hat{S}(t) \pm 1.96 \cdot \sqrt{\widehat{\text{Var}}(\hat{S}(t))} \quad (6)$$

2.4 การทดสอบสมมติฐาน Log-Rank Test

เพื่อทดสอบว่าฟังก์ชันการอยู่รอดของกลุ่มลูกค้า K กลุ่มมีความแตกต่างกันอย่างมีนัยสำคัญหรือไม่ กำหนดสมมติฐาน:

$$H_0 : S_1(t) = S_2(t) = \dots = S_K(t) \quad (\text{ทุกกลุ่มมีวิธีการอยู่รอดเหมือนกัน})$$

$$H_1 : \text{มีอย่างน้อยหนึ่งกลุ่มที่มีฟังก์ชันการอยู่รอดแตกต่างออกไป}$$

สถิติทดสอบ Log-Rank (χ^2) เปรียบเทียบผลต่างระหว่างจำนวนเหตุการณ์ที่สังเกตได้จริง (O_j) กับค่าคาดหวังภายใต้ H_0 (E_j):

$$\chi^2 = \sum_{j=1}^K \frac{(O_j - E_j)^2}{V_j} \sim \chi^2(K - 1) \quad (7)$$

3 Dataset Overview & Preprocessing (ชุดข้อมูลและการเตรียมตัวแปร)

ชุดข้อมูล Telco-Churn.csv มีโครงสร้างขนาด 7,043 แถว และ 21 คอลัมน์ โดยประกอบด้วยตัวแปรที่นำมาใช้ในการวิเคราะห์ดังนี้:

- **Duration Variable (T):** คอลัมน์ tenure แทนระยะเวลา (เดือน) ที่ลูกค้าผูกพันกับผู้ให้บริการ ($0 \leq T \leq 72$)
- **Event Indicator (E):** คอลัมน์ Churn แปลงเป็น $E = 1$ เมื่อ Churn = 'Yes' (เกิดเหตุการณ์) และ $E = 0$ เมื่อ Churn = 'No' (ถูก Right-Censored)
- **Segmentation Covariate:** คอลัมน์ PaymentMethod แบ่งเป็น 4 กลุ่ม ได้แก่ Electronic check, Mailed check, Bank transfer (automatic) และ Credit card (automatic)


ตารางที่ 1: สถิติเชิงพรรณนาภาพรวมของชุดข้อมูล Telco Churn ($N = 7,043$)

กลุ่มสถานะลูกค้า (Status)	จำนวน (Observations)	สัดส่วน (%)	ค่าเฉลี่ย Tenure (เดือน)
ลูกค้าที่ยกเลิกบริการจริง (Churned Events: $E = 1$)	1,869	26.54%	17.98
ลูกค้าที่ยังคงใช้บริการอยู่ (Censored: $E = 0$)	5,174	73.46%	37.57
รวมประชากรทั้งหมด (Total Cohort)	7,043	100.00%	32.37

4 Experimental Results & Diagnostic Plots (ผลลัพธ์การวิเคราะห์และกราฟสถิติ)

4.1 1. เส้นโค้งการอยู่รอดของประชากรโดยรวม (Overall Survival Curve)

จากการฟิตโมเดล Kaplan-Meier บนกลุ่มลูกค้าทั้งหมด 7,043 ราย ได้เส้นโค้งการอยู่รอดดังแสดงใน Figure 1




รูปที่ 1: Overall Customer Kaplan-Meier Survival Curve $\hat{S}(t)$: เส้นโค้งการอยู่รอดของลูกค้าภาพรวม ($N = 7,043$) พร้อมช่วงความเชื่อมั่น 95% โดยแสดงค่าความน่าจะเป็น ณ ช่วงเวลาสำคัญ $S(12) = 83.9\%$, $S(24) = 78.4\%$, $S(48) = 68.8\%$ และ $S(72) = 58.7\%$


การแปลผล Figure 1: ค่าความน่าจะเป็นในการอยู่รอดของลูกค้าภาพรวมลดลงอย่างต่อเนื่องแต่คงตัวได้ดี โดยมีลูกค้าถึง 83.9% ที่อยู่รอดเกิน 1 ปี และ 58.7% ที่ยังคงใช้บริการอยู่จนถึงสิ้นสุดการศึกษาที่ 6 ปี (72 เดือน) เนื่องจากมีผู้รอดชีวิตเกิน 50% ตลอด 72 เดือน ค่ามัธยฐานการอยู่รอด (Median Survival Time) จึงมากกว่า 72 เดือน (Not reached within study window)

4.2 2. เปรียบเทียบเส้นโค้งการอยู่รอดตามช่องทางการชำระเงิน (Survival Curves by Payment Method)

เมื่อจำแนกลูกค้าออกเป็น 4 กลุ่มตามช่องทางการชำระเงิน ได้เส้นโค้งเปรียบเทียบดังแสดงใน Figure 2 และ Figure 3




รูปที่ 2: **Comparative Kaplan-Meier Survival Curves by Payment Method:** เปรียบเทียบเส้นโค้งการอยู่รอดระหว่าง 4 ช่องทางชำระเงิน พบว่ากลุ่ม Electronic check มีอัตราการลดลงของความน่าจะเป็นในการอยู่รอดรวดเร็วและรุนแรงที่สุด โดยตัดผ่านเส้นมัธยฐานที่ $t = 47.0$ เดือน



รูปที่ 3: **Individual Kaplan-Meier Facet Plots with 95% CI:** กราฟแยกย่อย 2×2 พร้อมแถบช่วงความเชื่อมั่น 95% แบบ Greenwood แสดงให้เห็นความแม่นยำสูงเนื่องจากขนาดกลุ่มตัวอย่างที่ใหญ่ ($n \geq 1,522$ ในทุกกลุ่ม)

4.3 3. การวิเคราะห์ ความเสี่ยง สะสม (Cumulative Hazard Function Analysis)


ฟังก์ชันความเสี่ยงสะสม $\Lambda(t) = -\ln S(t)$ แสดงอัตราการสะสมของความเสี่ยงในการยกเลิกบริการตามระยะเวลาการใช้งาน ดังแสดงใน Figure 4



รูปที่ 4: Cumulative Hazard Curves $\Lambda(t)$ by Payment Method: เส้นความเสี่ยงสะสมของกลุ่ม Electronic check มีความชันสูงมาก ($\Lambda(72) > 1.2$) บ่งชี้ว่าลูกค้ารายใหม่ที่เลือกจ่ายด้วยช่องทางนี้มีความเสี่ยงในการยกเลิกบริการสูงตลอดทุกช่วงเวลา ต่างจากระบบอัตโนมัติที่มีความเสี่ยงสะสมคงที่ในระดับต่ำ ($\Lambda(72) \approx 0.28 - 0.30$)

4.4 4. การแจกแจงอัตรา Churn และระยะเวลา Tenure

Figure 5 แสดงอัตรา Churn (%) เปรียบเทียบกับกล่องการแจกแจงระยะเวลา Tenure ของลูกค้าแต่ละกลุ่ม



รูปที่ 5: Churn Rate & Tenure Distribution by Payment Method: ช่าย: อัตรา Churn ของ Electronic check สูงถึง 45.3% ขวา: แผนภาพ Boxplot แสดงค่ามัธยฐาน Tenure ของกลุ่มระบบตัดเงินอัตโนมัติที่สูงถึงประมาณ 43 เดือน

4.5 5. ตารางสรุปผลลัพธ์เชิงปริมาณ (Quantitative Summary of Results)

ตารางที่ 2: สรุปผลการวิเคราะห์การอยู่รอดเชิงปริมาณ จำแนกตามช่องทางการชำระเงิน

Payment Method	Sample n	Churn d	Censor c	Churn Rate	Median Surv.	Mean Tenure	$S(12)$	$S(24)$	$S(36)$	$S(48)$	$S(72)$
Electronic check	2,365	1,071	1,294	45.3%	47.0 mo.	25.2 mo.	0.727	0.624	0.553	0.493	0.295
Mailed check	1,612	308	1,304	19.1%	> 72 mo.	21.8 mo.	0.828	0.797	0.769	0.740	0.726
Bank transfer (auto)	1,544	258	1,286	16.7%	> 72 mo.	43.7 mo.	0.931	0.902	0.878	0.847	0.745
Credit card (auto)	1,522	232	1,290	15.2%	> 72 mo.	43.3 mo.	0.945	0.913	0.887	0.855	0.758
Overall Population	7,043	1,869	5,174	26.5%	> 72 mo.	32.4 mo.	0.839	0.784	0.738	0.688	0.587

4.6 6. ผลการทดสอบทางสถิติ Log-Rank Test

ตารางที่ 3: ผลการทดสอบความแตกต่างของเส้นโค้งการอยู่รอด (Multivariate & Pairwise Log-Rank Tests)

การเปรียบเทียบ (Comparison)	Chi-Square (χ^2)	p -value	ข้อสรุปทางสถิติ ($\alpha = 0.001$)
Multivariate (All 4 Groups)	865.2395	3.07×10^{-187}	ปฏิเสธ H_0 (แตกต่างกันอย่างมีนัยสำคัญยิ่ง)
Bank transfer (auto) vs Credit card (auto)	0.8683	0.3514	ไม่แตกต่างกันทางสถิติ (H_0 ถูกยอมรับ)
Electronic check vs Bank transfer (auto)	510.0351	$< 10^{-100}$	แตกต่างกันอย่างมีนัยสำคัญยิ่ง
Electronic check vs Credit card (auto)	539.7402	$< 10^{-100}$	แตกต่างกันอย่างมีนัยสำคัญยิ่ง
Electronic check vs Mailed check	152.4555	$< 10^{-30}$	แตกต่างกันอย่างมีนัยสำคัญยิ่ง
Mailed check vs Bank transfer (auto)	51.0719	$< 10^{-11}$	แตกต่างกันอย่างมีนัยสำคัญยิ่ง
Mailed check vs Credit card (auto)	64.8152	$< 10^{-14}$	แตกต่างกันอย่างมีนัยสำคัญยิ่ง

5 In-depth Discussion & Business Insights (การอภิปรายผลเชิงลึก)

5.1 1. การวิเคราะห์กลุ่มความเสี่ยงสูง: Electronic Check

ลูกค้ากลุ่มที่ชำระผ่าน **Electronic check** เป็นกลุ่มที่มีขนาดใหญ่ที่สุด ($n = 2,365$ หรือ 33.58% ของประชากร) แต่กลับมีอัตราการยกเลิกบริการสูงที่สุดถึง 45.3% (1,071 ราย) และมี **Median Survival Time** เท่ากับ 47.0 เดือน

- **พฤติกรรมและความเสียดทานในการชำระ (Payment Friction):** การจ่ายผ่านเช็คอิเล็กทรอนิกส์มักเป็นการจ่ายแบบ Manual ในแต่ละรอบบิล ทำให้ลูกค้าต้องเผชิญกับ “จุดตัดสินใจ (Decision Point)” ทุก ๆ เดือนว่าจะชำระต่อหรือยกเลิกบริการ
- **ความสัมพันธ์กับสัญญาแบบ Month-to-Month:** กลุ่มลูกค้าเช็คอิเล็กทรอนิกส์ส่วนใหญ่มีสัดส่วนสัญญาแบบรายเดือนสูง ทำให้ความยืดหยุ่นในการยกเลิกบริการทำได้ง่ายกว่ากลุ่มที่มีสัญญาระยะยาว

5.2 2. ประสิทธิภาพของระบบชำระเงินอัตโนมัติ (Automatic Payment Channels)

กลุ่มลูกค้าที่ใช้ **Bank transfer (automatic)** และ **Credit card (automatic)** มีคุณลักษณะการอยู่รอดที่ดีเยี่ยมและใกล้เคียงกันมาก โดยผลการทดสอบ Pairwise Log-Rank ยืนยันว่าไม่มีความแตกต่างกันอย่างมีนัยสำคัญทางสถิติ ($p = 0.3514$):

- อัตรา Churn ต่ำมากเพียง 15.2% – 16.7%
- ค่าความน่าจะเป็นในการอยู่รอดเกิน 2 ปี ($S(24)$) สูงเกิน 90% (90.2% – 91.3%)
- **กลไกเชิงพฤติกรรม:** ระบบตัดเงินอัตโนมัติช่วยขจัดความตระหนักรู้ถึงค่าใช้จ่ายในแต่ละรอบบิล (Pain of Paying) และลดความยุ่งยากในการทำธุรกรรม ส่งผลให้ลูกค้าคงสถานะการใช้บริการอย่างยาวนาน

5.3 3. พฤติกรรมเฉพาะตัวของกลุ่ม Mailed Check

กลุ่ม **Mailed check** มีอัตรา Churn รวมค่อนข้างต่ำ (19.1%) และมีค่า $S(72) = 72.6\%$ แต่มีค่าเฉลี่ย Tenure สั้น (21.8 เดือน):

- ในช่วง 12 เดือนแรก มีอัตราการลดลงของเส้นการอยู่รอดที่ค่อนข้างชัน ($S(12) = 82.8\%$) ซึ่งสะท้อนถึงกลุ่มผู้ทดลองใช้บริการระยะสั้น
- แต่เมื่อลูกค้ากลุ่มนี้ผ่านช่วง 24 เดือนแรกไปได้ เส้นโค้งการอยู่รอดจะแบนราบลงอย่างเห็นได้ชัด ($S(72) = 72.6\%$) แสดงว่าลูกค้าที่เหลืออยู่คือกลุ่มผู้ใช้ที่มีความภักดีสูง (Brand Loyalists) เช่น กลุ่มผู้สูงอายุหรือลูกค้าดั้งเดิม

6 Strategic Recommendations (ข้อเสนอแนะเชิงกลยุทธ์)

ข้อเสนอแนะเชิงกลยุทธ์สำหรับฝ่ายบริหารและฝ่ายการตลาด:

1. **แคมเปญ กระตุ้น การ เปลี่ยน ผ่าน สู่ Auto-Pay (Incentivize Auto-Pay Migration):** มอบส่วนลดพิเศษ เช่น ส่วนลดค่าบริการ \$5 ต่อเดือน เป็นเวลา 6 เดือน สำหรับลูกค้าที่เปลี่ยนช่องทางจาก Electronic check หรือ Mailed check มาเป็นระบบตัดบัตรเครดิตหรือบัญชีธนาคารอัตโนมัติ ซึ่งจะช่วยลด Churn Rate ได้ทันทีกว่า 28–30%
2. **การแทรกแซงเชิงรุกในช่วง Tenure 0–12 เดือน (Early Onboarding Intervention):** จากกราฟ Hazard อัตราเสี่ยงต่อการยกเลิกจะสะสมตัวเร็วที่สุดในช่วงปีแรก ควรจัดทีม Customer Success ติดตามความพึงพอใจและเสนอสัญญาณรายปีพร้อมข้อเสนอพิเศษก่อนที่ลูกค้าจะเข้าสู่เดือนที่ 12
3. **ระบบแจ้งเดือนและชำระเงินแบบ One-Click Billing:** ปรับปรุงกระบวนการชำระเงินของ Electronic check ให้มีความสะดวกรวดเร็ว ลดความยุ่งยากของขั้นตอนทางธุรกรรมเพื่อลดแรงจูงใจในการยกเลิกบริการ

7 Conclusion (สรุปผลการดำเนินงาน)

การวิเคราะห์การอยู่รอดด้วยแบบจำลอง Kaplan-Meier บนชุดข้อมูล Telco Churn ช่วยให้เราเข้าใจพลวัตของระยะเวลาในการคงอยู่ของลูกค้าได้อย่างแม่นยำเหนือกว่าแบบจำลองการถดถอยทั่วไป ผลการทดสอบทางสถิติ Log-Rank Test ($\chi^2 = 865.24, p = 3.07 \times 10^{-187}$) ชี้ชัดว่าช่องทางการชำระเงินเป็นปัจจัยที่มีอิทธิพลต่อความอยู่รอดของลูกค้าอย่างมีนัยสำคัญยิ่ง โดยกลุ่มระบบตัดเงินอัตโนมัติมีประสิทธิภาพในการรักษาสถานลูกค้าสูงสุด ($S(24) > 90\%$) ในขณะที่กลุ่ม Electronic check เป็นกลุ่มความเสี่ยงสูงที่ต้องได้รับการปรับปรุงเชิงกลยุทธ์อย่างเร่งด่วน

A Source Code Implementation (ภาคผนวก: โค้ดโปรแกรม ภาษา Python)

Listing 1: โปรแกรมการวิเคราะห์การอยู่รอด Kaplan-Meier และ Log-Rank Test บน Telco Churn Dataset

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 from lifelines import KaplanMeierFitter, NelsonAalenFitter
5 from lifelines.statistics import multivariate_logrank_test,
   pairwise_logrank_test
6
7 # 1. Load data and extract time-to-event variables
8 df = pd.read_csv('Telco-Churn.csv')
9 T = df['tenure']
10 E = (df['Churn'] == 'Yes').astype(int)
11
12 # 2. Overall Kaplan-Meier Survival Estimation
13 kmf_overall = KaplanMeierFitter()
14 kmf_overall.fit(T, event_observed=E, label='All Customers (N =
   7,043)')
15
16 # 3. Segmented Survival by Payment Method
17 methods = ['Electronic check', 'Mailed check', 'Bank transfer (
   automatic)', 'Credit card (automatic)']
18 kmf_dict = {}
19
20 plt.figure(figsize=(9, 5.5))
21 ax = plt.subplot(111)
22
23 for method in methods:
24     mask = (df['PaymentMethod'] == method)
25     kmf = KaplanMeierFitter()
26     kmf.fit(T[mask], event_observed=E[mask], label=method)
27     kmf_dict[method] = kmf
28     kmf.plot_survival_function(ax=ax, ci_show=True)
29
30 plt.title('Kaplan-Meier Survival Curves by Payment Method')
31 plt.xlabel('Tenure (Months)')
32 plt.ylabel('Survival Probability S(t)')
33 plt.ylim(0, 1.05)
34 plt.grid(True, linestyle='--', alpha=0.5)
```

```
35 plt.savefig('plot_2_km_by_payment.pdf', bbox_inches='tight')
36 plt.show()
37
38 # 4. Multivariate Log-Rank Test
39 logrank_res = multivariate_logrank_test(T, df['PaymentMethod'], E)
40 print(f"Chi-square: {logrank_res.test_statistic:.4f}, p-value: {
    logrank_res.p_value:.4e}")
41
42 # 5. Pairwise Log-Rank Test
43 pairwise_res = pairwise_logrank_test(T, df['PaymentMethod'], E)
44 print(pairwise_res.summary)
```