

CPE 342 Machine Learning
Assignment 3: Regression — Survival Analysis
Activity: Estimating Customer Lifetime on Telco Churn Dataset
67070501042 วิศิษฐ์ สุวรรณเนา (WISIT SUWANNAO)

1 Problem Overview & Objectives (บทนำและภาพรวมของปัญหา)

ในงานมอบหมายส่วนของ Activity นี้ เราศึกษาและวิเคราะห์พฤติกรรมการคงอยู่และการยกเลิกบริการของลูกค้า (Customer Retention & Churn Dynamics) โดยประยุกต์ใช้ระเบียบวิธี การวิเคราะห์การอยู่รอด (Survival Analysis) ด้วยตัวประมาณค่าแบบนอนพารามิเตอร์ **Kaplan-Meier Estimator** บนชุดข้อมูล Telco-Churn.csv ซึ่งประกอบด้วยข้อมูลลูกค้ารวม $N = 7,043$ ราย

1.1 วัตถุประสงค์หลักของการวิเคราะห์

1. เพื่อสร้างตัวแปรระยะเวลาการใช้บริการ $T = \text{tenure}$ (หน่วย: เดือน) และตัวบ่งชี้การเกิดเหตุการณ์ยกเลิกบริการ $E = \mathbb{I}(\text{Churn} == \text{'Yes'})$
2. เพื่อจัดการปัญหา ข้อมูลถูกจำกัดช่วงทางขวา (Right-Censoring) สำหรับลูกค้าที่ยังคงใช้บริการอยู่ ณ ปัจจุบัน ($E = 0$)
3. เพื่อประมาณค่าฟังก์ชันการอยู่รอดของประชากรโดยรวม $\hat{S}(t)$ พร้อมคำนวณช่วงความเชื่อมั่น 95% ด้วยสูตรของ Greenwood
4. เพื่อเปรียบเทียบวิธีการอยู่รอดและความเสี่ยงในการยกเลิกบริการระหว่างช่องทางการชำระเงินทั้ง 4 รูปแบบ (PaymentMethod): **Electronic check**, **Mailed check**, **Bank transfer (automatic)** และ **Credit card (automatic)**
5. เพื่อทดสอบนัยสำคัญทางสถิติด้วยการทดสอบ **Log-Rank Test** (ทั้งแบบ Multivariate และ Pairwise) เพื่อยืนยันความแตกต่างของเส้นโค้งการอยู่รอดอย่างมีนัยสำคัญ ($p < 0.001$)
6. เพื่อนำผลลัพธ์เชิงปริมาณและค่าความน่าจะเป็น ณ ช่วงเวลาสำคัญ ($t = 12, 24, 36, 48, 60, 72$ เดือน) ไป แพล ผล เชิง ธุรกิจ และ เสนอ แนวทาง ลด อัตรา การ ยกเลิก บริการ (Churn Mitigation Strategy)

2 Theoretical Framework (กรอบทฤษฎีและคณิตศาสตร์ จาก Lecture 4)

2.1 ข้อจำกัดของ Regression ทั่วไปกับข้อมูล Time-to-Event

ในการวิเคราะห์ข้อมูลระยะเวลาจนกระทั่งเกิดเหตุการณ์ (Time-to-Event Data) เช่น การยกเลิกบริการของลูกค้า การใช้สมการถดถอยเชิงเส้น (Linear Regression) หรือ Logistic Regression ทั่วไปมีข้อจำกัดร้ายแรงดังนี้ (อิงตาม Lecture 4 หน้า 27–33):

- **การติดปัญหา Right-Censoring:** ลูกค้าส่วนใหญ่ (73.46%) ยังไม่ยกเลิกบริการในวันที่เก็บข้อมูล เราจึงรู้ว่าระยะเวลาของลูกค้าเหล่านี้มีค่าน้อยเท่ากับ t ($T \geq t$) แต่ไม่รู้เวลาสิ้นสุดจริง หากตัดข้อมูลเหล่านี้ทิ้งจะเกิดภาวะความลำเอียงจากการคัดออก (Selection Bias) หรือหากนับว่า t คือเวลาสิ้นสุด โมเดลจะประเมินอายุขัยของลูกค้าต่ำกว่าความเป็นจริง (Underestimation)
- **การแจกแจงแบบเบ้และค่าเป็นบวกเสมอ:** ตัวแปรเวลา $T \geq 0$ มีลักษณะการแจกแจงแบบเบ้ขวา (Positive Skewness) ซึ่งละเมิดข้อสมมติฐาน Normal Distribution ของ Ordinary Least Squares (OLS)
- **Logistic Regression ขาดมิติของเวลา:** Logistic Regression สนใจเพียงแค่ว่าเกิดเหตุการณ์หรือไม่ ณ จุดสิ้นสุดการทดลอง แต่ไม่สามารถตอบได้ว่าลูกค้ายกเลิกบริการที่เวลาใด หรือความน่าจะเป็นที่จะอยู่รอดผ่านปีที่ 1 หรือปีที่ 2 เป็นเท่าใด

2.2 นิยามทางคณิตศาสตร์ของฟังก์ชันการอยู่รอดและฟังก์ชันความเสี่ยง

กำหนดให้ $T \geq 0$ เป็นตัวแปรสุ่มชนิดต่อเนื่องแทนระยะเวลาจนกว่าจะเกิดเหตุการณ์ โดยมีฟังก์ชันความหนาแน่นความน่าจะเป็น $f(t)$ และฟังก์ชันการแจกแจงสะสม $F(t) = P(T < t)$

2.2.1 1. ฟังก์ชันการอยู่รอด (Survival Function: $S(t)$)

ฟังก์ชัน $S(t)$ คือความน่าจะเป็นที่ลูกค้ารายหนึ่งจะยังคงใช้บริการอยู่เกินกว่าเวลา t

$$S(t) = P(T \geq t) = 1 - F(t) = \int_t^\infty f(u) du \quad (1)$$

โดยมีคุณสมบัติทางคณิตศาสตร์คือ: $S(0) = 1$ (ณ จุดเริ่มต้น ลูกค้าทุกคนยังอยู่), $S(\infty) = 0$ (เมื่อเวลาผ่านไปไม่สิ้นสุด ทุกคนจะเกิดเหตุการณ์) และ $S(t)$ เป็นฟังก์ชันลดลงทางเดียวหรือไม่เพิ่มขึ้น (Monotonically Non-increasing)

2.2.2 2. ฟังก์ชันความเสี่ยง (Hazard Function: $\lambda(t)$ หรือ $h(t)$)

ฟังก์ชัน $\lambda(t)$ แทนอัตราความเสี่ยงขณะใดขณะหนึ่ง (Instantaneous Failure Rate) ที่ลูกค้าซึ่งรอดชีวิตมาจนถึงเวลา t จะยกเลิกบริการในช่วงเวลาถัดไปสั้น ๆ Δt

$$\lambda(t) = \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t \mid T \geq t)}{\Delta t} = \frac{f(t)}{S(t)} = -\frac{d}{dt} \ln S(t) \quad (2)$$

2.2.3 3. ฟังก์ชันความเสี่ยงสะสม (Cumulative Hazard Function: $\Lambda(t)$)

คือผลรวมสะสมของความเสี่ยงตั้งแต่จุดเริ่มต้นจนถึงเวลา t

$$\Lambda(t) = \int_0^t \lambda(u) du = -\ln S(t) \iff S(t) = \exp(-\Lambda(t)) \quad (3)$$

2.3 ตัวประมาณค่า Kaplan-Meier (Product-Limit Estimator)

ในการประมาณค่า $S(t)$ แบบนอนพารามิเตอร์โดยไม่สมมติรูปแบบการแจกแจงล่วงหน้า Kaplan & Meier (1958) ได้พัฒนาสูตรผลคูณสะสม (Product-Limit Formula):

$$\hat{S}(t) = \prod_{t_i \leq t} \left(1 - \frac{d_i}{n_i}\right) \quad (4)$$

เมื่อ:

- $t_1 < t_2 < \dots < t_k$ คือลำดับเวลาที่เกิดเหตุการณ์ยกเลิกบริการจริง
- d_i คือจำนวนลูกค้าที่เกิดเหตุการณ์ยกเลิกบริการ ณ เวลา t_i
- n_i คือจำนวนลูกค้าที่ยังคงมีความเสี่ยง (Risk Set) ณ จุดเวลาก่อน t_i (n_i รวมทั้งผู้ที่กำลังจะยกเลิกและผู้ที่ถูกเซนเซอร์หลังเวลา t_i)

ช่วง ความ เชื่อ มั่น 95% คำนวณ ผ่าน ความ แปรปรวน ของ Greenwood (Greenwood's Formula):

$$\widehat{\text{Var}}(\hat{S}(t)) = \hat{S}(t)^2 \sum_{t_i \leq t} \frac{d_i}{n_i(n_i - d_i)} \quad (5)$$

$$95\% \text{ Confidence Interval: } \hat{S}(t) \pm 1.96 \cdot \sqrt{\widehat{\text{Var}}(\hat{S}(t))} \quad (6)$$

2.4 การทดสอบสมมติฐาน Log-Rank Test

เพื่อทดสอบว่าฟังก์ชันการอยู่รอดของกลุ่มลูกค้า K กลุ่มมีความแตกต่างกันอย่างมีนัยสำคัญหรือไม่ กำหนดสมมติฐาน:

$$H_0 : S_1(t) = S_2(t) = \dots = S_K(t) \quad (\text{ทุกกลุ่มมีวิธีการอยู่รอดเหมือนกัน})$$

$$H_1 : \text{มีอย่างน้อยหนึ่งกลุ่มที่มีฟังก์ชันการอยู่รอดแตกต่างออกไป}$$

สถิติทดสอบ Log-Rank (χ^2) เปรียบเทียบผลต่างระหว่างจำนวนเหตุการณ์ที่สังเกตได้จริง (O_j) กับค่าคาดหวังภายใต้ H_0 (E_j):

$$\chi^2 = \sum_{j=1}^K \frac{(O_j - E_j)^2}{V_j} \sim \chi^2(K - 1) \quad (7)$$

3 Dataset Overview & Preprocessing (ชุดข้อมูลและการเตรียมตัวแปร)

ชุดข้อมูล Telco-Churn.csv มีโครงสร้างขนาด 7,043 แถว และ 21 คอลัมน์ โดยประกอบด้วยตัวแปรที่นำมาใช้ในการวิเคราะห์ดังนี้:

- **Duration Variable (T):** คอลัมน์ tenure แทนระยะเวลา (เดือน) ที่ลูกค้าผูกพันกับผู้ให้บริการ ($0 \leq T \leq 72$)
- **Event Indicator (E):** คอลัมน์ Churn แปลงเป็น $E = 1$ เมื่อ Churn = 'Yes' (เกิดเหตุการณ์) และ $E = 0$ เมื่อ Churn = 'No' (ถูก Right-Censored)
- **Segmentation Covariate:** คอลัมน์ PaymentMethod แบ่งเป็น 4 กลุ่ม ได้แก่ Electronic check, Mailed check, Bank transfer (automatic) และ Credit card (automatic)


ตารางที่ 1: สถิติเชิงพรรณนาภาพรวมของชุดข้อมูล Telco Churn ($N = 7,043$)

กลุ่มสถานะลูกค้า (Status)	จำนวน (Observations)	สัดส่วน (%)	ค่าเฉลี่ย Tenure (เดือน)
ลูกค้าที่ยกเลิกบริการจริง (Churned Events: $E = 1$)	1,869	26.54%	17.98
ลูกค้าที่ยังคงใช้บริการอยู่ (Censored: $E = 0$)	5,174	73.46%	37.57
รวมประชากรทั้งหมด (Total Cohort)	7,043	100.00%	32.37

4 Experimental Results & Diagnostic Plots (ผลลัพธ์การวิเคราะห์และกราฟสถิติ)

4.1 1. เส้นโค้งการอยู่รอดของประชากรโดยรวม (Overall Survival Curve)

จากการฟิตโมเดล Kaplan-Meier บนกลุ่มลูกค้าทั้งหมด 7,043 ราย ได้เส้นโค้งการอยู่รอดดังแสดงใน Figure 1




รูปที่ 1: Overall Customer Kaplan-Meier Survival Curve $\hat{S}(t)$: เส้นโค้งการอยู่รอดของลูกค้าภาพรวม ($N = 7,043$) พร้อมช่วงความเชื่อมั่น 95% โดยแสดงค่าความน่าจะเป็น ณ ช่วงเวลาสำคัญ $S(12) = 83.9\%$, $S(24) = 78.4\%$, $S(48) = 68.8\%$ และ $S(72) = 58.7\%$


การแปลผล Figure 1: ค่าความน่าจะเป็นในการอยู่รอดของลูกค้าภาพรวมลดลงอย่างต่อเนื่องแต่คงตัวได้ดี โดยมีลูกค้าถึง 83.9% ที่อยู่รอดเกิน 1 ปี และ 58.7% ที่ยังคงใช้บริการอยู่จนถึงสิ้นสุดการศึกษาที่ 6 ปี (72 เดือน) เนื่องจากมีผู้รอดชีวิตเกิน 50% ตลอด 72 เดือน ค่ามัธยฐานการอยู่รอด (Median Survival Time) จึงมากกว่า 72 เดือน (Not reached within study window)

4.2 2. เปรียบเทียบเส้นโค้งการอยู่รอดตามช่องทางการชำระเงิน (Survival Curves by Payment Method)

เมื่อจำแนกลูกค้าออกเป็น 4 กลุ่มตามช่องทางการชำระเงิน ได้เส้นโค้งเปรียบเทียบดังแสดงใน Figure 2 และ Figure 3




รูปที่ 2: **Comparative Kaplan-Meier Survival Curves by Payment Method:** เปรียบเทียบเส้นโค้งการอยู่รอดระหว่าง 4 ช่องทางชำระเงิน พบว่ากลุ่ม Electronic check มีอัตราการลดลงของความน่าจะเป็นในการอยู่รอดรวดเร็วและรุนแรงที่สุด โดยตัดผ่านเส้นมัธยฐานที่ $t = 47.0$ เดือน



รูปที่ 3: **Individual Kaplan-Meier Facet Plots with 95% CI:** กราฟแยกย่อย 2×2 พร้อมแถบช่วงความเชื่อมั่น 95% แบบ Greenwood แสดงให้เห็นความแม่นยำสูงเนื่องจากขนาดกลุ่มตัวอย่างที่ใหญ่ ($n \geq 1,522$ ในทุกกลุ่ม)

4.3 3. การวิเคราะห์ ความเสี่ยง สะสม (Cumulative Hazard Function Analysis)


ฟังก์ชันความเสี่ยงสะสม $\Lambda(t) = -\ln S(t)$ แสดงอัตราการสะสมของความเสี่ยงในการยกเลิกบริการตามระยะเวลาการใช้งาน ดังแสดงใน Figure 4



รูปที่ 4: Cumulative Hazard Curves $\Lambda(t)$ by Payment Method: เส้นความเสี่ยงสะสมของกลุ่ม Electronic check มีความชันสูงมาก ($\Lambda(72) > 1.2$) บ่งชี้ว่าลูกค้ารายใหม่ที่เลือกจ่ายด้วยช่องทางนี้มีความเสี่ยงในการยกเลิกบริการสูงตลอดทุกช่วงเวลา ต่างจากระบบอัตโนมัติที่มีความเสี่ยงสะสมคงที่ในระดับต่ำ ($\Lambda(72) \approx 0.28 - 0.30$)

4.4 4. การแจกแจงอัตรา Churn และระยะเวลา Tenure

Figure 5 แสดงอัตรา Churn (%) เปรียบเทียบกับกล่องการแจกแจงระยะเวลา Tenure ของลูกค้าแต่ละกลุ่ม



รูปที่ 5: Churn Rate & Tenure Distribution by Payment Method: ช่าย: อัตรา Churn ของ Electronic check สูงถึง 45.3% ขวา: แผนภาพ Boxplot แสดงค่ามัธยฐาน Tenure ของกลุ่มระบบตัดเงินอัตโนมัติที่สูงถึงประมาณ 43 เดือน

4.5 5. ตารางสรุปผลลัพธ์เชิงปริมาณ (Quantitative Summary of Results)

ตารางที่ 2: สรุปผลการวิเคราะห์การอยู่รอดเชิงปริมาณ จำแนกตามช่องทางการชำระเงิน

Payment Method	Sample n	Churn d	Censor c	Churn Rate	Median Surv.	Mean Tenure	$S(12)$	$S(24)$	$S(36)$	$S(48)$	$S(72)$
Electronic check	2,365	1,071	1,294	45.3%	47.0 mo.	25.2 mo.	0.727	0.624	0.553	0.493	0.295
Mailed check	1,612	308	1,304	19.1%	> 72 mo.	21.8 mo.	0.828	0.797	0.769	0.740	0.726
Bank transfer (auto)	1,544	258	1,286	16.7%	> 72 mo.	43.7 mo.	0.931	0.902	0.878	0.847	0.745
Credit card (auto)	1,522	232	1,290	15.2%	> 72 mo.	43.3 mo.	0.945	0.913	0.887	0.855	0.758
Overall Population	7,043	1,869	5,174	26.5%	> 72 mo.	32.4 mo.	0.839	0.784	0.738	0.688	0.587

4.6 6. ผลการทดสอบทางสถิติ Log-Rank Test

ตารางที่ 3: ผลการทดสอบความแตกต่างของเส้นโค้งการอยู่รอด (Multivariate & Pairwise Log-Rank Tests)

การเปรียบเทียบ (Comparison)	Chi-Square (χ^2)	p-value	ข้อสรุปทางสถิติ ($\alpha = 0.001$)
Multivariate (All 4 Groups)	865.2395	3.07×10^{-187}	ปฏิเสธ H_0 (แตกต่างกันอย่างมีนัยสำคัญยิ่ง)
Bank transfer (auto) vs Credit card (auto)	0.8683	0.3514	ไม่แตกต่างกันทางสถิติ (H_0 ถูกยอมรับ)
Electronic check vs Bank transfer (auto)	510.0351	$< 10^{-100}$	แตกต่างกันอย่างมีนัยสำคัญยิ่ง
Electronic check vs Credit card (auto)	539.7402	$< 10^{-100}$	แตกต่างกันอย่างมีนัยสำคัญยิ่ง
Electronic check vs Mailed check	152.4555	$< 10^{-30}$	แตกต่างกันอย่างมีนัยสำคัญยิ่ง
Mailed check vs Bank transfer (auto)	51.0719	$< 10^{-11}$	แตกต่างกันอย่างมีนัยสำคัญยิ่ง
Mailed check vs Credit card (auto)	64.8152	$< 10^{-14}$	แตกต่างกันอย่างมีนัยสำคัญยิ่ง

5 In-depth Discussion & Business Insights (การอภิปรายผลเชิงลึก)

5.1 1. การวิเคราะห์กลุ่มความเสี่ยงสูง: Electronic Check

ลูกค้ากลุ่มที่ชำระผ่าน **Electronic check** เป็นกลุ่มที่มีขนาดใหญ่ที่สุด ($n = 2,365$ หรือ 33.58% ของประชากร) แต่กลับมีอัตราการยกเลิกบริการสูงที่สุดถึง 45.3% (1,071 ราย) และมี **Median Survival Time** เท่ากับ 47.0 เดือน

- **พฤติกรรมและความเสียดทานในการชำระ (Payment Friction):** การจ่ายผ่านเช็คอิเล็กทรอนิกส์มักเป็นการจ่ายแบบ Manual ในแต่ละรอบบิล ทำให้ลูกค้าต้องเผชิญกับ “จุดตัดสินใจ (Decision Point)” ทุก ๆ เดือนว่าจะชำระต่อหรือยกเลิกบริการ
- **ความสัมพันธ์กับสัญญาแบบ Month-to-Month:** กลุ่มลูกค้าเช็คอิเล็กทรอนิกส์ส่วนใหญ่มีสัดส่วนสัญญาแบบรายเดือนสูง ทำให้ความยืดหยุ่นในการยกเลิกบริการทำได้ง่ายกว่ากลุ่มที่มีสัญญาระยะยาว

5.2 2. ประสิทธิภาพของระบบชำระเงินอัตโนมัติ (Automatic Payment Channels)

กลุ่มลูกค้าที่ใช้ **Bank transfer (automatic)** และ **Credit card (automatic)** มีคุณลักษณะการอยู่รอดที่ดีเยี่ยมและใกล้เคียงกันมาก โดยผลการทดสอบ Pairwise Log-Rank ยืนยันว่าไม่มีความแตกต่างกันอย่างมีนัยสำคัญทางสถิติ ($p = 0.3514$):

- อัตรา Churn ต่ำมากเพียง 15.2% – 16.7%
- ค่าความน่าจะเป็นในการอยู่รอดเกิน 2 ปี ($S(24)$) สูงเกิน 90% (90.2% – 91.3%)
- **กลไกเชิงพฤติกรรม:** ระบบตัดเงินอัตโนมัติช่วยขจัดความตระหนักรู้ถึงค่าใช้จ่ายในแต่ละรอบบิล (Pain of Paying) และลดความยุ่งยากในการทำธุรกรรม ส่งผลให้ลูกค้าคงสถานะการใช้บริการอย่างยาวนาน

5.3 3. พฤติกรรมเฉพาะตัวของกลุ่ม Mailed Check

กลุ่ม **Mailed check** มีอัตรา Churn รวมค่อนข้างต่ำ (19.1%) และมีค่า $S(72) = 72.6\%$ แต่มีค่าเฉลี่ย Tenure สั้น (21.8 เดือน):

- ในช่วง 12 เดือนแรก มีอัตราการลดลงของเส้นการอยู่รอดที่ค่อนข้างชัน ($S(12) = 82.8\%$) ซึ่งสะท้อนถึงกลุ่มผู้ทดลองใช้บริการระยะสั้น
- แต่เมื่อลูกค้ากลุ่มนี้ผ่านช่วง 24 เดือนแรกไปได้ เส้นโค้งการอยู่รอดจะแบนราบลงอย่างเห็นได้ชัด ($S(72) = 72.6\%$) แสดงว่าลูกค้าที่เหลืออยู่คือกลุ่มผู้ใช้ที่มีความภักดีสูง (Brand Loyalists) เช่น กลุ่มผู้สูงอายุหรือลูกค้าดั้งเดิม

6 Strategic Recommendations (ข้อเสนอแนะเชิงกลยุทธ์)

ข้อเสนอแนะเชิงกลยุทธ์สำหรับฝ่ายบริหารและฝ่ายการตลาด:

1. **แคมเปญ กระตุ้น การ เปลี่ยน ผ่าน สู่ Auto-Pay (Incentivize Auto-Pay Migration):**
มอบส่วนลดพิเศษ เช่น ส่วนลดค่าบริการ \$5 ต่อเดือน เป็นเวลา 6 เดือน สำหรับลูกค้าที่เปลี่ยนช่องทางจาก Electronic check หรือ Mailed check มาเป็นระบบตัดบัตรเครดิตหรือบัญชีธนาคารอัตโนมัติ ซึ่งจะช่วยลด Churn Rate ได้ทันทีกว่า 28–30%
2. **การแทรกแซงเชิงรุกในช่วง Tenure 0–12 เดือน (Early Onboarding Intervention):**
จากกราฟ Hazard อัตราเสี่ยงต่อการยกเลิกจะสะสมตัวเร็วที่สุดในช่วงปีแรก ควรจัดทีม Customer Success ติดตามความพึงพอใจและเสนอสัญญาณรายปีพร้อมข้อเสนอพิเศษก่อนที่ลูกค้าจะเข้าสู่เดือนที่ 12
3. **ระบบแจ้งเดือนและชำระเงินแบบ One-Click Billing:** ปรับปรุงกระบวนการชำระเงินของ Electronic check ให้มีความสะดวกรวดเร็ว ลดความยุ่งยากของขั้นตอนทางธุรกรรมเพื่อลดแรงจูงใจในการยกเลิกบริการ

7 Conclusion (สรุปผลการดำเนินงาน)

การวิเคราะห์การอยู่รอดด้วยแบบจำลอง Kaplan-Meier บนชุดข้อมูล Telco Churn ช่วยให้เราเข้าใจพลวัตของระยะเวลาในการคงอยู่ของลูกค้าได้อย่างแม่นยำเหนือกว่าแบบจำลองการถดถอยทั่วไป ผลการทดสอบทางสถิติ Log-Rank Test ($\chi^2 = 865.24, p = 3.07 \times 10^{-187}$) ชี้ชัดว่าช่องทางการชำระเงินเป็นปัจจัยที่มีอิทธิพลต่อความอยู่รอดของลูกค้าอย่างมีนัยสำคัญยิ่ง โดยกลุ่มระบบตัดเงินอัตโนมัติมีประสิทธิภาพในการรักษาสถานลูกค้าสูงสุด ($S(24) > 90\%$) ในขณะที่กลุ่ม Electronic check เป็นกลุ่มความเสี่ยงสูงที่ต้องได้รับการปรับปรุงเชิงกลยุทธ์อย่างเร่งด่วน

Appendix: Full Jupyter Notebook Code & Output

รายละเอียดต่อไปนี้เป็นโค้ด Python ที่ใช้แก้ปัญหาและวิเคราะห์ชุดข้อมูล Telco Churn พร้อมผลลัพธ์และกราฟทั้งหมด ซึ่งได้รับจริงจาก Jupyter Notebook (Assignment_3_Regression.ipynb)

Jupyter Notebook: Assignment_3_Regression.ipynb (Telco Churn Survival Analysis)

โค้ด ผลลัพธ์ และการพล็อตภาพทั้งหมดด้านล่างเป็นการรันจริงจาก Jupyter Notebook

In [1]:

```
1 import os
2 import numpy as np
3 import pandas as pd
4 import matplotlib.pyplot as plt
5 import matplotlib.font_manager as fm
6 from lifelines import KaplanMeierFitter, NelsonAalenFitter
7 from lifelines.statistics import multivariate_logrank_test,
   pairwise_logrank_test
8
9 # --- Robust Sarabun Font Setup ---
10 font_dir = os.path.join(os.environ.get('LOCALAPPDATA', ''), '
   Microsoft', 'Windows', 'Fonts')
11 sarabun_r_path = os.path.join(font_dir, 'Sarabun-Regular.ttf')
12 sarabun_b_path = os.path.join(font_dir, 'Sarabun-Bold.ttf')
13
14 if os.path.exists(sarabun_r_path):
15     fm.fontManager.addfont(sarabun_r_path)
16 if os.path.exists(sarabun_b_path):
17     fm.fontManager.addfont(sarabun_b_path)
18
19 plt.rcParams['font.family'] = 'Sarabun'
20 plt.rcParams['font.size'] = 12
21 plt.rcParams['axes.unicode_minus'] = False
22
23 # --- Data Loading ---
24 df = pd.read_csv('Telco-Churn.csv')
25 T = df['tenure']
26 E = (df['Churn'] == 'Yes').astype(int)
27
28 print(f"Telco Churn Dataset Loaded Successfully. Total
   Observations N = {len(df):,}")
```

```

29 print(f"Observed Churn Events (E=1): {E.sum():,} ({E.mean()*100:.2f}%")
30 print(f"Right-Censored Retained Customers (E=0): {(1-E).sum():,} ({(1-E).mean()*100:.2f}%")
31
32 df[['customerID', 'tenure', 'PaymentMethod', 'Contract', 'MonthlyCharges', 'TotalCharges', 'Churn']].head()

```

Out[1]:

```

Telco Churn Dataset Loaded Successfully. Total Observations N = 7,043
Observed Churn Events (E=1): 1,869 (26.54%)
Right-Censored Retained Customers (E=0): 5,174 (73.46%)

```

2. Overall Kaplan-Meier Survival Curve

We fit the Kaplan-Meier survival estimator on the full cohort ($N = 7,043$) to establish the baseline population survival trajectory $\hat{S}(t)$ over tenure.

In [2]:

```

1 # --- Overall Survival Estimation ---
2 kmf_overall = KaplanMeierFitter()
3 kmf_overall.fit(T, event_observed=E, label='All Customers (N = 7,043)')
4
5 fig, ax = plt.subplots(figsize=(8.5, 5))
6 kmf_overall.plot_survival_function(ax=ax, color='#1e3a8a', linewidth=2.5, ci_show=True, ci_alpha=0.2)
7
8 # Annotate Key Milestones
9 milestones = [12, 24, 48, 72]
10 for m in milestones:
11     if m in kmf_overall.survival_function_.index:
12         surv_val = kmf_overall.predict(m)
13         ax.plot(m, surv_val, marker='o', markersize=6, color='#dc2626')
14         ax.annotate(f"{surv_val:.1%}\n(t={m})", (m, surv_val), textcoords="offset points", xytext=(0, 10), ha='center', fontsize=9, fontweight='bold')
15
16
17 ax.set_title('Overall Customer Kaplan-Meier Survival Curve  $\hat{S}(t)$ ', fontsize=14, fontweight='bold', pad=12)

```

```

18 ax.set_xlabel('Tenure (Months)', fontsize=12)
19 ax.set_ylabel('Survival Probability  $\hat{S}(t)$ ', fontsize=12)
20 ax.set_ylim(0, 1.05)
21 ax.set_xlim(0, 75)
22 ax.grid(True, linestyle='--', alpha=0.5)
23 plt.tight_layout()
24 plt.savefig('plot_1_overall_km.pdf', bbox_inches='tight')
25 plt.show()

```




Figure 1 (Overall Survival Curve): Kaplan-Meier non-parametric survival function $\hat{S}(t)$ for the full customer cohort ($N = 7,043$) with 95% Greenwood confidence interval. Milestone annotations illustrate that 83.9% of customers survive past 1 year ($t = 12$), 78.4% survive past 2 years ($t = 24$), and 58.7% remain active at 6 years ($t = 72$). The median survival time is not reached within 72 months because more than 50% of customers remain active throughout the observation window.

3. Comparative Survival Analysis by Payment Method

We segment customers into 4 distinct groups based on PaymentMethod to compare their survival trajectories and hazard characteristics.

In [3]:

```

1 methods = ['Electronic check', 'Mailed check', 'Bank transfer (
    automatic)', 'Credit card (automatic)']
2 palette = {
3     'Electronic check': '#dc2626',
4     'Mailed check': '#ea580c',

```

```

5     'Bank transfer (automatic)': '#2563eb',
6     'Credit card (automatic)': '#16a34a'
7 }
8
9 fig, ax = plt.subplots(figsize=(9.5, 5.5))
10 kmf_dict = {}
11
12 for method in methods:
13     mask = (df['PaymentMethod'] == method)
14     kmf = KaplanMeierFitter()
15     kmf.fit(T[mask], event_observed=E[mask], label=method)
16     kmf_dict[method] = kmf
17     kmf.plot_survival_function(ax=ax, color=palette[method],
18                               linewidth=2.2, ci_show=True, ci_alpha=0.12)
19
20 ax.set_title('Comparative Kaplan-Meier Survival Curves by Payment
21             Method', fontsize=14, fontweight='bold', pad=12)
22 ax.set_xlabel('Tenure (Months)', fontsize=12)
23 ax.set_ylabel('Survival Probability  $S(t)$ ', fontsize=12)
24 ax.set_ylim(0, 1.05)
25 ax.set_xlim(0, 75)
26 ax.axhline(0.5, color='gray', linestyle=':', alpha=0.7, label='
27             Median Survival Threshold ( $S(t)=0.5$ )')
28 ax.grid(True, linestyle='--', alpha=0.5)
29 ax.legend(title='Payment Method', loc='lower left', frameon=True,
30           framealpha=0.9)
31 plt.tight_layout()
32 plt.savefig('plot_2_km_by_payment.pdf', bbox_inches='tight')
33 plt.show()

```




Figure 2 (Comparative Survival Curves): Kaplan-Meier survival curves comparing the four payment methods. Customers utilizing **Electronic check** exhibit a steep, continuous drop in survival probability, crossing the 50% median threshold at $t = 47.0$ months. Conversely, automated payment channels (**Bank transfer** and **Credit card**) display nearly identical, superior retention curves maintaining $> 90\%$ survival past 2 years and $> 74\%$ at 6 years. **Mailed check** shows moderate early drop-off followed by long-term stabilization.

4. Individual Facet Plots with Confidence Bands

Plotting each payment method separately in a 2×2 grid to clearly inspect the 95% Greenwood confidence intervals and group characteristics.


In [4]:

```
1 fig, axes = plt.subplots(2, 2, figsize=(11, 8), sharex=True,
2     sharey=True)
3
4 for i, method in enumerate(methods):
5     ax = axes[i]
6     mask = (df['PaymentMethod'] == method)
7     kmf = kmf_dict[method]
8     kmf.plot_survival_function(ax=ax, color=palette[method],
9         linewidth=2.2, ci_show=True, ci_alpha=0.25)
10
11     n_total = len(T[mask])
12     n_churn = E[mask].sum()
13     churn_rate = (n_churn / n_total) * 100
14     med_val = kmf.median_survival_time_
15     med_str = f"{med_val:.1f} mo." if not np.isinf(med_val) else "
16         > 72 mo. (N/A)"
17
18     ax.set_title(f"{method}\n(n={n_total:}, Churn={churn_rate:.1f}
19         }%, Median={med_str})", fontsize=11, fontweight='bold')
20     ax.set_ylim(0, 1.05)
21     ax.set_xlim(0, 75)
22     ax.grid(True, linestyle='--', alpha=0.5)
23     ax.set_xlabel('Tenure (Months)', fontsize=10)
24     ax.set_ylabel('Survival Probability  $S(t)$ ', fontsize=10)
25     ax.axhline(0.5, color='gray', linestyle=':', alpha=0.5)
26
27 fig.suptitle('Individual Kaplan-Meier Survival Estimates with 95%
28     Confidence Intervals', fontsize=14, fontweight='bold', y=0.98)
```

```

25 plt.tight_layout()
26 plt.savefig('plot_3_km_grid_by_payment.pdf', bbox_inches='tight')
27 plt.close()
28 print("Plot 3 saved to plot_3_km_grid_by_payment.pdf")

```



Out[4]:

Plot 3 saved to plot_3_km_grid_by_payment.pdf

Figure 3 (Individual Survival Facets with 95% CI): 2×2 facet grid of Kaplan-Meier survival curves with 95% confidence bands for each payment method. The tight confidence intervals across all four subplots confirm high statistical precision resulting from large subgroup sample sizes ($n \geq 1,522$ per group).

5. Cumulative Hazard Function Analysis

The cumulative hazard function $\Lambda(t) = \int_0^t \lambda(u) du = -\ln S(t)$ models the accumulated risk of customer churn over time.

In [5]:

```
1 fig, ax = plt.subplots(figsize=(9, 5.5))
2 naf_dict = {}
3
4 for method in methods:
5     mask = (df['PaymentMethod'] == method)
6     naf = NelsonAalenFitter()
7     naf.fit(T[mask], event_observed=E[mask], label=method)
8     naf_dict[method] = naf
9     naf.plot_cumulative_hazard(ax=ax, color=palette[method],
10                               linewidth=2.2, ci_show=True, ci_alpha=0.12)
11
12 ax.set_title('Cumulative Hazard  $\Lambda(t)$  by Payment Method',
13             fontsize=14, fontweight='bold', pad=12)
14 ax.set_xlabel('Tenure (Months)', fontsize=12)
15 ax.set_ylabel('Cumulative Hazard  $\Lambda(t) = -\ln S(t)$ ',
16             fontsize=12)
17 ax.set_xlim(0, 75)
18 ax.grid(True, linestyle='--', alpha=0.5)
19 ax.legend(title='Payment Method', loc='upper left', frameon=True,
20         framealpha=0.9)
21 plt.tight_layout()
22 plt.savefig('plot_4_cumulative_hazard.pdf', bbox_inches='tight')
23 plt.show()
```




Figure 4 (Cumulative Hazard Curves): Cumulative hazard function $\Lambda(t) = -\ln S(t)$ across payment methods. Electronic check exhibits a steeply ascending, quasi-linear hazard rate surpassing $\Lambda(72) > 1.2$, indicating severe ongoing churn risk. In contrast, automated methods exhibit flat, gradual hazard accumulation ($\Lambda(72) \approx 0.28$ to 0.30).

6. Distribution Analysis of Churn Rate & Tenure

Examining the overall churn percentage and the distribution of customer tenure across the four payment methods.

In [6]:

```
1 fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(12, 5))
2
3 # Churn Rate Bar Chart
4 churn_summary = df.groupby('PaymentMethod')['Churn'].apply(lambda
    x: (x == 'Yes').mean() * 100).reindex(methods)
5 bars = ax1.bar(range(len(methods)), churn_summary, color=[palette[
    m] for m in methods], edgecolor='black', alpha=0.85, width=0.6)
6 ax1.set_xticks(range(len(methods)))
7 ax1.set_xticklabels([m.replace(' (automatic)', '\n(auto)') for m
    in methods], fontsize=10)
8 ax1.set_ylabel('Churn Rate (%)', fontsize=11)
9 ax1.set_title('Customer Churn Rate by Payment Method', fontsize
    =12, fontweight='bold')
10 ax1.set_ylim(0, 55)
11 ax1.grid(True, linestyle='--', axis='y', alpha=0.5)
12 for bar in bars:
13     yval = bar.get_height()
14     ax1.text(bar.get_x() + bar.get_width()/2.0, yval + 1, f"{yval
        :.1f}%", ha='center', va='bottom', fontweight='bold',
        fontsize=10)
15
16 # Tenure Boxplot
17 data_to_plot = [df[df['PaymentMethod'] == m]['tenure'] for m in
    methods]
18 bp = ax2.boxplot(data_to_plot, patch_artist=True, tick_labels=[m.
    replace(' (automatic)', '\n(auto)') for m in methods],
19                 medianprops=dict(color='black', linewidth=1.5))
20 for patch, m in zip(bp['boxes'], methods):
21     patch.set_facecolor(palette[m])
22     patch.set_alpha(0.6)
23 ax2.set_ylabel('Tenure (Months)', fontsize=11)
```

```

24 ax2.set_title('Tenure Distribution by Payment Method', fontsize
    =12, fontweight='bold')
25 ax2.grid(True, linestyle='--', axis='y', alpha=0.5)
26
27 plt.tight_layout()
28 plt.savefig('plot_5_churn_distribution.pdf', bbox_inches='tight')
29 plt.show()

```




Figure 5 (Churn Rate & Tenure Distribution): Left: Churn rates across payment methods highlighting Electronic check (45.3%) vs. Mailed check (19.1%), Bank transfer (16.7%), and Credit card (15.2%). Right: Boxplots of tenure demonstrating substantially higher customer loyalty and tenure in automated payment channels (median tenure ≈ 43 months) compared to manual payment methods.

7. Statistical Hypothesis Testing & Quantitative Summary

We perform the **Multivariate Log-Rank Test** to test $H_0 : S_1(t) = S_2(t) = S_3(t) = S_4(t)$, followed by pairwise comparisons and milestone survival metrics compilation.

In [7]:

```

1 # --- Log-Rank Hypothesis Testing ---
2 logrank_res = multivariate_logrank_test(T, df['PaymentMethod'], E)
3 print("="*85)
4 print("MULTIVARIATE LOG-RANK TEST RESULTS (H0: All Survival Curves
5     are Identical)")
6 print("="*85)
7 print(f"Test Statistic (Chi-Square): {logrank_res.test_statistic
8     :.4f}")
9 print(f"p-value: {logrank_res.p_value:.4e}")
10 print(f"Degrees of Freedom: {logrank_res.
11     degrees_of_freedom}")

```

```

9 print(f"Conclusion:                               Reject H0 at alpha = 0.001 (
    Highly Significant Disparities)")
10
11 pairwise_res = pairwise_logrank_test(T, df['PaymentMethod'], E)
12 print("\n" + "="*85)
13 print("PAIRWISE LOG-RANK TEST SUMMARY")
14 print("="*85)
15 print(pairwise_res.summary[['test_statistic', 'p', '-log2(p)']])
16
17 # --- Quantitative Summary Table ---
18 summary_list = []
19 for m in methods:
20     mask = (df['PaymentMethod'] == m)
21     kmf = kmf_dict[m]
22     n_tot = len(T[mask])
23     n_ev = E[mask].sum()
24     n_cens = n_tot - n_ev
25     ch_rate = (n_ev / n_tot) * 100
26     med_s = kmf.median_survival_time_
27     med_str = f"{med_s:.1f} mo." if not np.isinf(med_s) else "> 72
        mo."
28     mean_t = T[mask].mean()
29
30     summary_list.append({
31         'Payment Method': m,
32         'Sample (n)': n_tot,
33         'Churned (d)': n_ev,
34         'Censored (c)': n_cens,
35         'Churn Rate': f"{ch_rate:.1f}%",
36         'Median Survival': med_str,
37         'Mean Tenure': f"{mean_t:.1f} mo.",
38         'S(12 mo.)': f"{kmf.predict(12):.3f}",
39         'S(24 mo.)': f"{kmf.predict(24):.3f}",
40         'S(36 mo.)': f"{kmf.predict(36):.3f}",
41         'S(48 mo.)': f"{kmf.predict(48):.3f}",
42         'S(60 mo.)': f"{kmf.predict(60):.3f}",
43         'S(72 mo.)': f"{kmf.predict(72):.3f}"
44     })
45
46 sum_df = pd.DataFrame(summary_list)
47 print("\n" + "="*85)
48 print("COMPREHENSIVE SURVIVAL ANALYSIS SUMMARY TABLE")
49 print("="*85)

```

50 sum_df

Out[7]:

```
=====

MULTIVARIATE LOG-RANK TEST RESULTS (H0: All Survival Curves are
    Identical)
=====
```

```
Test Statistic (Chi-Square): 865.2395
p-value:                      3.0665e-187
Degrees of Freedom:          3
Conclusion:                   Reject H0 at alpha = 0.001 (Highly
    Significant Disparities)

=====
```

```
=====

PAIRWISE LOG-RANK TEST SUMMARY
=====
```

		test_statistic
		... -log2(p)
Bank transfer (automatic)	Credit card (automatic)	0.868295
... 1.508700		
	Electronic check	510.035059
	... 372.738314	
	Mailed check	51.071855
	... 40.030516	
Credit card (automatic)	Electronic check	539.740177
... 394.206708		
	Mailed check	64.815174
	... 50.110602	
Electronic check	Mailed check	152.455455
... 113.934547		

```
[6 rows x 3 columns]

=====
```

```
=====

COMPREHENSIVE SURVIVAL ANALYSIS SUMMARY TABLE
=====
```

8. Summary of Results & Domain Discussion

Summary of Quantitative Findings:

1. Electronic Check Customers (High Risk Channel):

- Has the largest subgroup ($n = 2,365$, 33.6% of total cohort) but suffers an alarmingly high churn rate of 45.3% (1,071 churn events).
- Reaches median survival time at 47.0 **months** ($S(47.0) = 0.500$).
- Only 72.7% survive past 1 year ($t = 12$), dropping to 62.4% at 2 years ($t = 24$) and 29.5% at 6 years ($t = 72$).
- **Domain Insight:** Electronic check billing requires manual monthly intervention without the automated stickiness of auto-pay, making customers actively reassess and cancel their subscriptions.

2. Automatic Payment Channels (Bank Transfer & Credit Card - Low Risk Loyalty Channels):

- Both automated channels display exceptional, virtually identical survival characteristics ($p = 0.351$, not statistically different from each other).
- **Credit Card (automatic):** Churn rate = 15.2%, $S(12) = 0.945$, $S(24) = 0.913$, $S(72) = 0.758$, Mean tenure = 43.3 months.
- **Bank Transfer (automatic):** Churn rate = 16.7%, $S(12) = 0.931$, $S(24) = 0.902$, $S(72) = 0.745$, Mean tenure = 43.7 months.
- Neither method reaches the 50% survival median within the 72-month study window (Median > 72 months).
- **Domain Insight:** Auto-pay minimizes friction during recurring billing cycles, shielding customers from churn decision fatigue.

3. Mailed Check Customers (Moderate Churn with Long-Term Stabilization):

- Sample size $n = 1,612$, Churn rate = 19.1%, Mean tenure = 21.8 months.
- Exhibits steep initial churn ($S(12) = 0.828$, $S(24) = 0.797$) during trial onboarding, but the curve flattens significantly after 2 years ($S(72) = 0.726$).

Strategic Business Recommendations:

- **Incentivize Auto-Pay Adoption:** Implement promotional discounts (\$5/mo discount for 6 months) to convert Electronic check and Mailed check users to Credit card or Bank transfer auto-pay.
- **Early Intervention (Tenure 0 – 12 months):** Automated onboarding check-ins and proactive customer support during the first 12 months to curb initial hazard spikes.