



Machine Learning

Machine Learning

Lecture 4: Regression

Asst. Prof. Dr. Santitham Prom-on

Department of Computer Engineering, Faculty of Engineering
King Mongkut's University of Technology Thonburi



$$y = f(x)$$

- # Lab



https://drive.google.com/file/d/12lm4MO-xYqFZb-gp_VChhDncPjg_PPet/view?usp=sharing

15m15 word 80% pdf

Input x Output y

Simple linear regression

- Simple linear regression model has one input x and one output y .
- The relationship can be explain as the following equation

$$f(x) = w_0 + w_1x$$

$w_1 > 0$ เพิ่มขึ้น

$w_1 < 0$ ลดลง

- Mathematically, parameters are obtained by least square method

Input features $x_1, x_2, x_3, \dots$ (Features) # features

Multiple regression (GLM)

General Linear Regression Model

- Multiple linear regression model structure is exactly the same as the linear regression

Independent
↙

$$f(\mathbf{x}) = w_0 + w_1x_1 + w_2x_2 + \dots$$

- Mathematically, parameters are obtained by least square method

Multiple regression with interaction

ตัวแปรทำงานร่วมกัน มีผลซึ่งกันและกัน

- Adding **interaction terms** to a regression model can greatly expand understanding of the relationships among the variables in the model โลกด.เป็นจริง attributes ไม่ได้อิสระต่อกันหมด
- This occurs when two or more variables depend on one another for the outcome

$$f(\mathbf{x}) = w_0 + w_1x_1 + w_2x_2 + \underbrace{w_3x_1x_2}_{\text{ผลของ } x_1, x_2 \text{ เป็นอิสระต่อกัน}} + \dots$$

x_1, x_2 ทำงานกัน $w_3 < 0$ คือ $x_1 \propto \frac{1}{x_2}$

Ex: สม.ดอกเบี้ยเงินกู้ยืม, สม.ป.นอน

Feature selection via shrinkage (Regularization)

- Instead of explicitly selecting features, in some approaches we can bias the learning process towards using a small number of features
- Key ideas: objective function has two parts

Loss function มี 2 ส่วน → • Term representing error minimization
Regularization มี 2 ส่วน → • Term that shrinks parameters toward 0

ปัญหาใน Regression : มี predictors มากเกินไป ทำให้ model ซับซ้อนเกินไป, coefficient มีขนาดใหญ่มาก, overfitting
วิธีแก้ปัญหานี้คือ การใช้ subset ของ predictors ที่ดีที่สุด

วิธี Shrinkage Methods แทนที่จะเลือกเฉพาะตัวแปรที่เราใช้ทุกตัวแปรแล้ว แต่ใส่ constraint ใน coefficient ให้ น้อยลงได้
∵ Coefficient ใน σ^2 ใหญ่ → σ^2 ใหญ่, ถ้า coefficient เป็น 0 ใน model นั้นจะดีกว่า เพราะมันจะลดความซับซ้อนลง

→ Technique ที่ใช้ Ridge Regression
Lasso Regression



Shrinkage and regression

- Consider the case of linear regression

$$y = f(x) = w_0 + \sum_{i=1}^n w_i x_i$$

- The standard approach minimizes sum squared error

Error function :

SSE
Sum of Square Error

$$E(w) = \sum_{d \in D} \left(y^{(d)} - f(x^{(d)}) \right)^2$$
$$= \sum_{d \in D} \left(y^{(d)} - w_0 - \sum_{i=1}^n w_i x_i^{(d)} \right)^2$$

Error function
ฟังก์ชันข้อผิดพลาด

ลด coefficients ให้เข้า 0 (ทำให้ไม่ 0)
 ให้อ่านว่า coeff "reduce"

ลด coefficient บางตัวจนเป็น 0 (ตัดตัวไปเลย)
 ให้อ่านว่า coeff "Love"

Ridge regression and the Lasso

Ridge, Lasso
 เพิ่ม term
 เข้าไปด้วย

- Ridge regression adds a penalty term, the L2 norm of the weights

$$E(w) = \sum_{d \in D} \left(y^{(d)} - w_0 - \sum_{i=1}^n w_i x_i^{(d)} \right)^2 + \lambda \sum_{i=1}^n w_i^2$$

turning parameter $\lambda \geq 0$ ให้อ่านว่า: ให้อ่านว่า penalty มีค่ามากขึ้น
 $\lambda = 0$: penalty 0 ให้อ่านว่า ridge regression coefficient ไม่ถูกปรับให้เข้า 0
 $\lambda \rightarrow \infty$: ridge regression coefficient เข้า 0
 Shrinkage penalty ให้อ่านว่า: ให้อ่านว่า $w_1, \dots, w_n$ เข้า 0
 ไม่ปรับ w_0 : ให้อ่านว่า shrink intercept

- The Lasso method adds a penalty term, the L₁ norm of the weights

$$E(w) = \sum_{d \in D} \left(y^{(d)} - w_0 - \sum_{i=1}^n w_i x_i^{(d)} \right)^2 + \lambda \sum_{i=1}^n |w_i|$$

ลด w ให้เข้า 0



diff $E(w)$ ให้เข้า 0 ให้อ่านว่า
 ให้อ่านว่า: ให้อ่านว่า $\frac{d}{dw} = 2w$

Lasso optimization

- Lasso stands for “least absolute shrinkage and selection operator

$$E(w) = \sum_{d \in D} \left(y^{(d)} - w_0 - \sum_{i=1}^n w_i x_i^{(d)} \right)^2 + \lambda \sum_{i=1}^n |w_i|$$

- This is equivalent to the following constrained optimization problem

$$E(w) = \sum_{d \in D} \left(y^{(d)} - w_0 - \sum_{i=1}^n w_i x_i^{(d)} \right)^2 \quad \text{subject to} \quad \sum_{i=1}^n |w_i| \leq t$$

$\lambda \approx \sum_{i=1}^n |w_i|$ is the L1 norm of w

$\downarrow$
 L1 norm

แนวคิดหลัก

Lasso Regression และ Ridge Regression ต่างก็พยายามทำให้ค่าความผิดพลาด (RSS หรือ Residual Sum of Squares) เล็กที่สุด แต่เพิ่มเงื่อนไข (constraint) เข้าไปเพื่อควบคุมขนาดของค่าพารามิเตอร์ β เงื่อนไขพวกนี้ทำให้โมเดลไม่ "ฟิต" เกินไป (overfitting) และช่วยเลือกตัวแปรได้ดีขึ้น

สมการในรูปแบบ Constraint

1. Lasso (สมการ 6.8)

$$\text{minimize}_{\beta} \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 \quad \text{subject to} \quad \sum_{j=1}^p |\beta_j| \leq s$$

- เงื่อนไข: ผลรวมค่าตัวสัมบูรณ์ $|\beta_j|$ ต้องไม่เกิน s
- ทำให้บาง β_j อาจถูกบังคับให้เป็นศูนย์เลย $\rightarrow$ Lasso ช่วยเลือกตัวแปร (feature selection)

2. Ridge (สมการ 6.9)

$$\text{minimize}_{\beta} \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 \quad \text{subject to} \quad \sum_{j=1}^p \beta_j^2 \leq s$$

- เงื่อนไข: ผลรวมกำลังสอง β_j^2 ต้องไม่เกิน s
- ทำให้ค่าของ β_j เล็กลงแต่ไม่เป็นศูนย์จริง ๆ $\rightarrow$ Ridge ลดขนาดพารามิเตอร์ แต่ไม่เลือกตัวแปรออก

การมองภาพ (เมื่อ $p = 2$)

- เงื่อนไข Lasso: $|\beta_1| + |\beta_2| \leq s \rightarrow$ พื้นที่เป็น รูปสี่เหลี่ยมข้าวหลามตัด (diamond)
- เงื่อนไข Ridge: $\beta_1^2 + \beta_2^2 \leq s \rightarrow$ พื้นที่เป็น วงกลม

การตีความ

- ถ้า s ใหญ่มาก $\rightarrow$ เงื่อนไขไม่ค่อยจำกัด $\rightarrow$ คำตอบจะเหมือน Least Squares ธรรมดา
- ถ้า s เล็ก $\rightarrow$ ต้องบีบให้ β_j เล็กลง
 - Lasso: บางค่าอาจกลายเป็นศูนย์ (เลือกตัวแปรให้อัตโนมัติ)
 - Ridge: ทุกค่าจะเล็กลง แต่ไม่มีค่าไหนเป็นศูนย์พอดี

Ridge regression and Lasso




FIGURE 3.11. Estimation picture for the lasso (left) and ridge regression (right). Shown are contours of the error and constraint functions. The solid blue areas are the constraint regions $|\beta_1| + |\beta_2| \leq t$ and $\beta_1^2 + \beta_2^2 \leq t^2$, respectively, while the red ellipses are the contours of the least squares error function.

Feature selection via shrinkage

- Lasso (L1) tends to make many weights 0, inherently performing feature selection
- Ridge regression (L2) shrinks weights but isn't as biased towards selecting features
- L1 and L2 penalties can be used with other learning methods (logistic regression, neural nets, SVMs, etc.)
- Both can help avoid overfitting by reducing variance
- There are many variants with somewhat different biases
 - elastic net: includes L1 and L2 penalties

98 L_1 L_2 ମିଶ୍ରଣ

As an optimization problem, binary class ℓ_2 penalized logistic regression minimizes the following cost function:

$$\text{L1} \quad \text{⑪_ratio} = 0 \quad \begin{array}{l} \text{100\% Manhattan con} \\ \text{99\% L2} \end{array} \quad \min_{w,c} \frac{1}{2} w^T w + C \sum_{i=1}^n \log(\exp(-y_i(X_i^T w + c)) + 1).$$

• $C \uparrow \rightarrow \text{un. error} \uparrow$
 • $C \downarrow \rightarrow \text{regularize more} \checkmark$ (model is less)

Similarly, ℓ_1 regularized logistic regression solves the following optimization problem:

$$\text{L1_ratio} = 1 \quad \begin{array}{l} \text{99\% Manhattan} \\ \text{99\% L2} \end{array} \quad \min_{w,c} \|w\|_1 + C \sum_{i=1}^n \log(\exp(-y_i(X_i^T w + c)) + 1).$$

Elastic-Net regularization is a combination of ℓ_1 and ℓ_2 , and minimizes the following cost function:

$$0 \leq \text{L1_ratio} \leq 1 \quad \min_{w,c} \frac{1-\rho}{2} w^T w + \rho \|w\|_1 + C \sum_{i=1}^n \log(\exp(-y_i(X_i^T w + c)) + 1),$$

L1_ratio : float or None, optional (default=None)

The Elastic-Net mixing parameter, with $0 \leq \text{L1_ratio} \leq 1$. Only used if `penalty='elasticnet'`. Setting `L1_ratio=0` is equivalent to using `penalty='l2'`, while setting `L1_ratio=1` is equivalent to using `penalty='l1'`. For $0 < \text{L1_ratio} < 1$, the penalty is a combination of L1 and L2.

Embedded approach *involves feature selection*

Logistic regression

```
[45] lr = LogisticRegression(penalty = 'l1', C=0.1, solver='liblinear')  
lr.fit(X_train, y_train)
```

▼ LogisticRegression
LogisticRegression(C=0.1, penalty='l1', solver='liblinear')

Embedded approach

Logistic regression

```
[46] lr.coef_[0]
```


```
array([ 4.39645027e-01,  0.00000000e+00,  0.00000000e+00,  3.64882336e-01,
        0.00000000e+00,  0.00000000e+00,  0.00000000e+00,  0.00000000e+00,
        0.00000000e+00,  0.00000000e+00,  0.00000000e+00,  0.00000000e+00,
        0.00000000e+00,  0.00000000e+00,  0.00000000e+00,  5.38658322e-01,
        1.08934507e+00, -1.10260038e-02, -3.53481268e-04,  3.35990896e-02,
        0.00000000e+00, -2.10427843e-01,  2.69803017e-03, -2.26244263e-01,
        0.00000000e+00, -1.45808259e-01, -1.18404056e-04,  7.08198896e-06,
        1.36897240e-01,  0.00000000e+00,  1.39256563e-01, -1.07618808e-01,
        -1.17913518e-01, -1.94316308e-02, -3.42778865e-02, -7.65126263e-02,
        3.73647156e-02, -1.03708133e-01,  1.20789097e-01, -6.54389495e-02])
```

```
▶ X_train.columns[lr.coef_[0]>0.001]
```


```
Index(['BusinessTravel_Travel_Frequently', 'Department_Sales',
       'MaritalStatus_Single', 'OverTime_Yes', 'DistanceFromHome',
       'HourlyRate', 'NumCompaniesWorked', 'PerformanceRating',
       'YearsAtCompany', 'YearsSinceLastPromotion'],
      dtype='object')
```

Embedded approach

Logistic regression



Generalized linear model





Poisson Regression



Poisson regression

So far we have looked at 2 kinds of regression

- Linear regression (simple, multiple) *y is normal distribution*
 - *Output: จำนวนเฉลี่ย* Continuous response, normally distributed with constant variance
 - Mean a linear function of the covariates
- “Logistic regression”
 - Response (number of successes in n trials) has a binomial distribution $\text{Bin}(n, p)$
 - Mean is np where log-odds of p is a linear function of the covariates

$$\begin{aligned}
 \text{logistic regression: } \log \frac{p}{1-p} &= f(x) & \left| \begin{aligned} p(1+e^{f(x)}) &= e^{f(x)} \\ p &= \frac{e^{f(x)}}{1+e^{f(x)}} \end{aligned} \right. \\
 \frac{p}{1-p} &= e^{f(x)} & \left| \begin{aligned} \text{in odd ratio } \frac{p}{1-p} > 1 & \text{ (success > failure)} \\ \text{in } \log \frac{p}{1-p} > 1 & \rightarrow f(x) \text{ is up} \end{aligned} \right. \\
 p &= \frac{e^{f(x)}}{1+e^{f(x)}} & \left| \begin{aligned} \text{in odd ratio } \frac{p}{1-p} < 1 & \text{ (success < failure)} \\ \text{in } \log \frac{p}{1-p} < 1 & \rightarrow f(x) \text{ is down} \end{aligned} \right.
 \end{aligned}$$

Ex: - ใน 5 นาที เราจะได้ class ใหม่ 5 คน
- มี #รถที่วิ่งอยู่ในถนนสายนี้กี่คัน
- #ครั้งที่เราจะเจอคนใน 1 ปี

Poisson regression (cont)

- Now we consider “Poisson regression”
 - Response is a count, assumed to have a Poisson distribution with (positive) mean μ *output is discrete*
 - Assume that $\log \mu$ is a linear function of the covariates
 - Alternatively,
$$\mu = \exp(\text{linear function of covariates})$$
- Poisson is a standard distribution when response is a count.

Poisson distribution

$$\Pr(Y = y) = \frac{e^{-\mu} \mu^y}{y!}$$

Count Y can have values $0, 1, 2, \dots$

(thus, mean μ must be positive)

The Poisson Regression Model

- The response Y with covariates $x_1, \dots, x_k$ has a Poisson distribution, with mean μ
- Mean μ is related to the covariates by

unlike linear regression
we model $\log(\mu)$ instead of μ

$$\log(\mu) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$$


$\mu = e^{(\beta_0 + \beta_1 x_1 + \dots + \beta_k x_k)}$

- As for logistic regression, the parameters are estimated by maximum likelihood

Interpretation of β 's

- If $\beta_j > 0$, mean *increases* with $x_j \rightarrow$ γ မြင့်တက်
- If $\beta_j < 0$, mean *decreases* with $x_j \rightarrow$ γ ကျဆင်း
- Unit increase in x_j changes the mean by a factor of $\exp(\beta_j)$
(like the odds in logistic regression)


Estimation of β 's



- To estimate the β 's, we use the method of *maximum likelihood*, as in logistic regression
ดร.เจษฎาภรณ์ อ.เนติวิทย์
- Basic idea:
 - Using the *Poisson* distribution, we can work out the probability of getting any particular set of responses y .
 - In particular, we can work out the probability of getting the data we actually observed – this is the likelihood
 - Choose β 's to maximise this probability (or, equivalently, the log-likelihood)

Example: Mining accident data

- This example features the number of accidents per mine in a 3 month period in 44 coal mines in West Virginia. The variables are
 - COUNT: the number of accidents (response)
 - INB: inner burden thickness
 - EXTRP: percentage of coal extracted from mine
 - AHS: the average height of the coal seam in the mine
 - AGE: the age of the mine






Survival analysis

Logistic regression vs time

$$\log \frac{p}{1-p} = f(x)$$

- In logistic regression, we were interested in studying how risk factors were associated with presence or absence of disease.
- Sometimes, we are interested in how a risk factor or treatment affects time to disease or some other event.
- In these cases, logistic regression is not appropriate.




→ Analyze the time until an event occurs.

Survival analysis

the censoring event time is the time at which censoring occurs: for example, the time at which the patient drops out of the study or the study ends.

- Survival analysis is used to analyze data in which the time until the event is of interest.
- The response is often referred to as a failure time, survival time, or event time.

→ represents the time at which the time event of interest occurs:




Example:

- Time until tumor recurrence
- Time until a machine part fails
- Time until mobile phone recharge
- Time until the next credit card usage

ใช้ predict ว่าลูกค้าคนต่อไป จะทำธุรกรรมอีกทีเมื่อไหร่

The survival time response

- Usually continuous *บางทีก็มี discrete ได้ Ex: วัน, เดือน, ปี*
- May be incompletely determined for some subjects
 - For some subjects we may know that their survival time was at least equal to some time t .
 - Whereas, for other subjects, we will know their exact time of event.
- Incompletely observed responses are **censored**
- Is always ≥ 0 .



(เวลา)
 Censored คือ พังการณาคัดทิ้งไปบางส่วน
 Ex: สิ้นใจ 12 เดือน $\therefore$ E, C
 9.1 อาจาคัดในสมการ
 นี้อาจมาจากการ observe เช่น นายศิริ
 เป็นโรคแทรกซ้อน, เกิดอุบัติเหตุ, สิ่งอื่นๆ

Analysis issue

linear regression / *linear regression* *linear regression*

- If there is no censoring, standard linear regression procedures could be used.
- However, these may be inadequate because
 - Time to event is restricted to be positive and has a skewed distribution.
 - The probability of surviving past a certain point in time may be of more interest than the expected time of event.
 - The hazard function, used for regression in survival analysis, can lend more insight into the failure mechanism than linear regression.

linear regression
linear regression
(skewness) ∴ linear
regression is Normal distribution
time & distribution



Censoring

เก็บข้อมูลอยู่ ผ่านไปซักพักก็ไม่ได้ติดตามแล้ว

↑ right-censoring


Ex: ศึกษาเวลาพักแหว: เริ่มชีวิต น.ส.ก.ร.ก.ม. อยู่ ผ่านไป 10 เดือน คนไข้ไม่กลับมา update อาการเลย
คือ เรา track เมาต์ไม่ได้แล้ว อย่างน้อยเราถือว่า 10 เดือนมีชีวิตอยู่ แต่อยู่อีกนานแค่ไหน
ก็ไม่สามารถที่เราไม่รู้

- Censoring is present when we have some information about a subject's event time, but we don't know the exact event time.
- For the analysis methods we will discuss to be valid, censoring mechanism must be independent of the survival mechanism.

Reasons censoring might occur

- A subject does not experience the event before the study ends
- A person is lost to follow-up during the study period
- A person withdraws from the study

These are all examples of **right-censoring**.



Ex: Covid-19 อากาศร้อนเกินไปแล้ว ตัวติดเครื่องปรับอากาศนี้แล้ว ไม่รู้ว่ามีอะไร

→ $S(t)$ มีหน่วยเป็น kg สูตรที่ 47: DM ที่ 0 เรามอง

Ex: หาค่า kg ที่จังหวัดเชียงใหม่ในหัวข้อ lecture

เวลาผ่านไปเรื่อยๆ จังหวัด kg ก็กลับมานั่นเอง

ประมาณ kg 0 คน

Survival function

- The survival function gives the probability that a subject will survive past time t .
- As t ranges from 0 to ∞ , the survival function has the following properties
 - It is non-increasing
 - At time $t=0$, $S(t) = 1$. In other words, the probability of surviving past time 0 is 1.
 - At time $t=\infty$, $S(t)=S(\infty)=0$. As time goes to infinity, the survival curve goes to 0.
- In theory, the survival function is smooth.
- In practice, we observe events on a discrete time scale (days, weeks, etc.).

ณ เวลานั้น โศกนาฏกรรมจะเกิดขึ้นเมื่อใด

- The hazard function, $h(t)$, is the instantaneous rate at which events occur, given no previous events.

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{\Pr(t < T \leq t + \Delta t | T > t)}{\Delta t} = \frac{f(t)}{S(t)}.$$

- The cumulative hazard describes the accumulated risk up to time t , $H(t) = \int_0^t h(u)du$.

Survival fn

If we know any one of the functions $S(t)$, $H(t)$, or $h(t)$, we can derive the other two functions.

$$h(t) = -\frac{\partial \log(S(t))}{\partial t}$$

$$H(t) = -\log(S(t))$$

$$S(t) = \exp(-H(t))$$

Survival data

How do we record and represent survival data with censoring?


- T_i denotes the response for the i th subject.
- Let C_i denote the censoring time for the i th subject
- Let δ_i denote the event indicator

$$\delta_i = \begin{cases} 1 & \text{if the event was observed } (T_i \leq C_i) \\ 0 & \text{if the response was censored } (T_i > C_i). \end{cases}$$

- The observed response is $Y_i = \min(T_i, C_i)$.

เวลาที่วัดได้

Example



Handwritten: δ_i survival fn

T_i	C_i	Y_i	δ_i
80	100	80	1
40	80	40	1
74+	74	74	0
85+	85	85	0
40	95	40	1

Handwritten: } censored

Estimating $S(t)$ and $H(t)$

If we are assuming that every subject follows the same survival function (no covariates or other individual differences), we can easily estimate $S(t)$.

- We can use nonparametric estimators like the Kaplan-Meier estimator
- We can estimate the survival distribution by making parametric assumptions
 - exponential
 - Weibull
 - Gamma
 - log-normal

Non-parametric estimation of S

- When no event times are censored, a non-parametric estimator of $S(T)$ is $1 - F_n(t)$, where $F_n(t)$ is the empirical cumulative distribution function.
- When some observations are censored, we can estimate $S(t)$ using the Kaplan-Meier product-limit estimator.

การคำนวณค่า $\frac{1}{n_i}$ หรือ $\frac{1}{b_i}$

+	b_i
---	-------


t	No. subjects at risk	Deaths	Censored	Cumulative survival
59	26	1	0	$25/26 = 0.962$
115	25	1	0	$24/25 \times 0.962 = 0.923$
156	24	1	0	$23/24 \times 0.923 = 0.885$
268	23	1	0	$22/23 \times 0.885 = 0.846$
329	22	1	0	$21/23 \times 0.846 = 0.808$
353	21	1	0	$20/21 \times 0.808 = 0.769$
365	20	0	1	$20/20 \times 0.769 = 0.769$
377	19	0	1	$19/19 \times 0.769 = 0.769$
421	18	0	1	$18/18 \times 0.769 = 0.769$
431	17	1	0	$16/17 \times 0.769 = 0.688$
⋮				⋮
⋮				⋮

(m+1)
การคำนวณ

Chain rule

การคำนวณ ไม่ censored

Survival curves by payment methods





End of Lecture 4

